



Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
Université de Tunis
Institut Supérieur de Gestion de Tunis (ISG)

RAPPORT DE STAGE DE FIN D'ÉTUDES

Pour l'obtention de la
Licence Appliquée en Informatique Décisionnelle

Mise en place d'un système décisionnel pour le produit
automobile de l'assurance BIAT

Entreprise d'accueil :
Assurances BIAT – Siège social



ASSURANCES BIAT

Élaboré par :
Amal Siala

Encadrants académiques :

Mme. Maha ELARBI
Mme. Imen OUESLATI

Encadrant professionnel :
Mr. Dhirar BEN YOUNESS

Année universitaire : 2024 – 2025

Remerciements

Ce travail marque l'aboutissement d'un parcours personnel et académique que je n'aurais jamais pu accomplir sans le soutien, l'amour et la confiance de nombreuses personnes précieuses dans ma vie.

Je tiens à remercier tout particulièrement *Mme Maha ELARBI*, pour son écoute attentive, sa bienveillance constante et ses conseils éclairés, qui m'ont beaucoup aidée à progresser. Elle a toujours su m'encourager dans les moments de doute. Mes remerciements vont également à *Mme. Imen OUESLATI*, pour son accompagnement, ainsi qu'à mes collègues *Tahar* et *Rihab*, pour leurs remarques constructives et leur aide précieuse tout au long de ce projet.

Je remercie chaleureusement *Mr. Dhirar BEN YOUNESS*, mon encadrant professionnel, de m'avoir offert l'opportunité d'effectuer ce stage au sein de l'assurance BIAT. Cette expérience a été un vrai tournant dans mon parcours professionnel.

À ma *mère*, je veux exprimer toute ma reconnaissance. Elle a tout donné pour moi, avec un courage immense et des sacrifices silencieux. Sa force et son amour sont à l'origine de chacune de mes réussites.

Je remercie de tout cœur ma *sœur*, qui a toujours été là pour moi, une présence rassurante, un appui dans les moments difficiles, une source de force et d'affection continue, ainsi que mon *petit frère*, pour sa présence précieuse dans ma vie et l'amour qu'il m'apporte au quotidien.

Merci à *Heni*, pour sa présence constante, ses encouragements, son écoute bienveillante et son soutien tout au long de cette aventure.

J'adresse aussi ma gratitude à tous mes amis pour leur motivation, leur bienveillance et leur soutien indéfectible à chaque étape.

Enfin, je dédie ce travail à ma *tante*, qui nous a quittés durant cette année difficile. Elle a été une seconde mère pour moi. J'aurais tant voulu qu'elle soit encore parmi nous pour partager ce moment et voir ce que j'ai accompli. Ce succès, je le lui offre de tout mon cœur, en hommage à son amour, à sa douceur et à tout ce qu'elle représentait pour moi.

Je tiens également à remercier tous les enseignants qui m'ont accompagnée au cours de ces trois années. Leur savoir, leur patience et leur engagement ont profondément enrichi mon parcours. Je me sens extrêmement chanceuse d'avoir étudié à l'ISG, un établissement qui m'a offert l'opportunité d'apprendre, de grandir et de me préparer sereinement à l'avenir.

Table des matières

Introduction générale	1
Chapitre 1 : Présentation générale du projet	2
1.1 Introduction	2
1.2 Présentation de l'assurance BIAT	2
1.2.1 Fiche signalétique	3
1.2.2 Organigramme hiérarchique de l'entreprise	3
1.2.3 Valeurs de l'assurance BIAT	4
1.2.4 Historique de l'assurance BIAT	4
1.2.5 Présentation du département contrôle de gestion	5
1.3 Contexte du projet	5
1.3.1 Analyse et critique de l'existant	6
1.3.2 Problématique	6
1.3.3 Solution proposée	6
1.4 Méthodologie de gestion du projet	7
1.4.1 Méthodologie Scrum	7
1.4.1.1 Avantages de Scrum	7
1.4.1.2 Limites de Scrum	8
1.4.2 Méthodologie GIMSI	8
1.4.2.1 Avantages de GIMSI	9
1.4.2.2 Limites de GIMSI	9
1.4.2.3 Comparaison entre Scrum et GIMSI	10
1.5 Méthodologie adoptée	10
1.6 Planification du projet	11
1.7 Conclusion	11
Chapitre 2 : Identification de l'environnement	12
2.1 Introduction	12
2.2 Environnement de l'entreprise	12
2.3 Processus de l'assurance BIAT	13
2.4 Établissements de l'assurance BIAT	13
2.5 Activités de l'assurance BIAT	13
2.6 Les acteurs de l'assurance BIAT	14
2.7 Les garanties de l'assurance automobile	15
2.8 Conclusion	16

Chapitre 3 : Conception	17
3.1 Introduction	17
3.2 Définition des principales exigences	17
3.2.1 Exigences fonctionnelles	17
3.2.2 Exigences non fonctionnelles	18
3.3 Construction du tableau de bord	18
3.3.1 Présentation du tableau de bord	18
3.3.2 Importance de la construction d'un tableau de bord	19
3.4 Collecte des informations	19
3.5 Sélection des indicateurs	19
3.6 Système de tableaux de bord	21
3.6.1 Approches de conception d'entrepôt de données	21
3.6.1.1 Approche Inmon	21
3.6.1.2 Approche Kimball	22
3.6.1.3 Comparaison des approches Inmon et Kimball	22
3.6.1.4 Approche adoptée	22
3.6.2 Schémas d'entrepôt de données	23
3.6.2.1 Schéma en étoile	24
3.6.2.2 Schéma en flocon de neige	24
3.6.2.3 Schéma en constellation de faits	25
3.6.2.4 Schéma adopté	26
3.7 Data Mart	26
3.8 Modèles de conception des tableaux de bord	27
3.8.1 Modèle de l'entrepôt de données	28
3.8.2 Prototypage des dashboards métiers	28
3.8.2.1 Modèle de dashboard pour l'analyse client	28
3.8.2.2 Modèle de dashboard pour l'analyse des contrats	29
3.8.2.3 Modèle de dashboard pour l'analyse des agences	30
3.9 Conclusion	30
Chapitre 4 : Implémentation et audit	31
4.1 Introduction	31
4.2 Processus ETL	31
4.3 Outils ETL choisis	31
4.3.1 Langage de programmation : Python	32
4.3.2 Environnement de développement : Spyder	32
4.3.3 Bibliothèques Python utilisées	33
4.3.4 Sources de données	34
4.3.5 Destination des données	34
4.3.6 Outil de visualisation : Power BI	34
4.4 Extraction des données	34
4.5 Transformation des données	35
4.5.1 Transformation des données avec Python	36
4.5.2 Transformation complémentaire avec Power BI	38
4.6 Chargement des données	39
4.7 Création des tableaux de bord	39
4.7.1 Tableau de bord analyse des clients	39
4.7.2 Tableau de bord analyse des contrats	41

4.7.3	Tableau de bord analyse des agences	43
4.8	Audit	45
4.9	Conclusion	45
Chapitre 5 : Analyse avancée des données des clients de l'assurance BIAT :		
	Prévision, segmentation et prédiction	46
5.1	Introduction	46
5.2	Prévision du chiffre d'affaires et du nombre de clients	46
5.2.1	Notions de base des séries temporelles	46
5.2.2	Analyse exploratoire des données	47
5.2.3	Étude de la stationnarité	47
5.2.3.1	Vérification de la stationnarité avec le test ADF	47
5.2.3.2	Stabilisation de la série temporelle	48
5.2.4	Division des données en des ensemble d'entraînement et de test	49
5.2.5	Création des modèles	49
5.2.5.1	Le modèle Holt-Winters	49
5.2.5.2	Le modèle XGBoost	50
5.2.5.3	Le modèle ARIMA saisonnier (SARIMA)	52
5.2.6	Évaluation de la performance des modèles	53
5.2.6.1	Les métriques d'évaluation	53
5.2.6.2	Résultats obtenus	55
5.2.7	Déploiement	55
5.3	Segmentation des clients	56
5.3.1	Préparation des données	56
5.3.2	Détermination du nombre optimal de clusters et application de l'algorithme K-Means	56
5.3.2.1	Choix du nombre de clusters	56
5.3.2.2	Application de l'algorithme K-Means pour la segmentation	57
5.3.3	Export des données segmentées	58
5.3.4	Intégration dans Power BI	59
5.4	Prédiction du comportement des clients	60
5.4.1	Préparation des données	60
5.4.2	Construction des modèles	61
5.4.2.1	Random Forest	61
5.4.2.2	Régression Logistique	62
5.4.3	Métriques d'évaluation	62
5.4.4	Résultats obtenus	63
5.4.5	Déploiement	65
5.4.5.1	Interface d'accueil	65
5.4.5.2	Interface de prédiction du comportement des clients	65
5.5	Conclusion	67
Conclusion générale		68

Liste des figures

1.1	Logo de l'assurance BIAT	2
1.2	Organigramme de l'assurance BIAT	4
1.3	Processus de Scrum	7
1.4	Processus GIMSI	8
1.5	Diagramme de Gantt représentant la planification du projet	11
3.1	Extrait du fichier Excel contenant les données contractuelles de BIAT As- surance	21
3.2	Illustration du schéma en étoile	24
3.3	Illustration du schéma en flocon de neige	25
3.4	Illustration du schéma en constellation de faits	26
3.5	Modèle de l'entrepôt de données	28
3.6	Dashboard "Analyse des clients"	29
3.7	Dashboard "Analyse des contrats"	29
3.8	Dashboard "Analyse des agences"	30
4.1	Logo Python	32
4.2	Logo Spyder	32
4.3	Logo Pandas	33
4.4	Logo Openpyxl	33
4.5	Logo Numpy	33
4.6	Logo Power BI	34
4.7	Extraction Excel	35
4.8	Exemple de script Python pour l'extraction des fichiers Excel	35
4.9	Chargement et nettoyage des fichiers Excel	36
4.10	Création de dictionnaires de mappage pour les agents et les régions	37
4.11	Création des colonnes	37
4.12	Création de la colonne Statut et normalisation du mois	37
4.13	Script d'export final de la base consolidée	38
4.14	Étapes de transformation effectuées dans Power Query	38
4.15	Tableau de bord "Analyse des clients"	40
4.16	Tableau de bord "Analyse des contrats"	42
4.17	Tableau de bord "Analyse des agences"	43
5.1	Script de préparation des données	47
5.2	Script du test statistique ADF	48
5.3	Résultats du test ADF	48
5.4	Script de division des données temporelles en ensembles d'entraînement et de test	49
5.5	Script de l'implémentation du modèle Holt-Winters	50
5.6	Illustration des résultats de prévision du chiffre d'affaires à l'aide du modèle Holt-Winters	50

5.7	Illustration des résultats de prévision du nombre de clients à l'aide du modèle Holt-Winters	50
5.8	Script de l'implémentation du modèle XGBoost	51
5.9	Illustration des résultats de prévision du chiffre d'affaires à l'aide du modèle XGBoost	51
5.10	Illustration des résultats de prévision du nombre de clients à l'aide du modèle XGBoost	52
5.11	Script de l'implémentation du modèle SARIMA	52
5.12	Illustration des résultats de prévision du chiffre d'affaires à l'aide du modèle SARIMA	53
5.13	Illustration des résultats de prévision du nombre de clients à l'aide du modèle SARIMA	53
5.14	Script de comparaison des modèles de prévision	54
5.15	Dashboard "Tableau de bord prévisionnel"	56
5.16	Script de l'implémentation de la méthode Elbow	57
5.17	Illustration du résultat de l'application de la méthode Elbow	57
5.18	Script de l'implémentation de l'algorithme K-Means	58
5.19	Visualisation de la segmentation des clients par K-Means	59
5.20	Tableau de bord "Segmentation des clients"	59
5.21	Aperçu des données sources après nettoyage	61
5.22	Script de l'implémentation du modèle Random Forest	62
5.23	Script de l'implémentation du modèle Régression Logistique	62
5.24	Matrice de confusion du modèle Random Forest	64
5.25	Matrice de confusion du modèle Régression Logistique	64
5.26	Page d'accueil	65
5.27	Interface interactive de prédiction du comportement des clients	66
5.28	Exemple de prédiction du comportement des clients	66

Liste des tableaux

1.1	Fiche signalétique de l'assurance BIA	3
1.2	Historique de l'assurance BIAT	5
1.3	Comparaison entre Scrum et GIMSI	10
2.1	Comparatif des garanties selon les formules d'assurance auto proposées par BIAT	15
3.2	Liste des KPI pour l'analyse des clients	20
3.3	Liste des KPI pour l'analyse des contrats	20
3.4	Liste des KPI pour l'analyse des agences	21
3.5	Approche Inmon	22
3.6	Approche Kimball	23
3.7	Comparaison entre les approches Inmon et Kimball	23
3.8	Description des tables de faits et de dimensions du data mart	27
4.9	Description des visuels du tableau de bord "Analyse des clients"	40
4.10	Description des visuels du tableau de bord "Analyse des contrats"	42
4.11	Description des visuels du tableau de bord "Analyse des agences"	44
5.12	Résultats obtenues par les trois modèles en comparaison (SARIMA, Holt-Winters et XGBoost) pour la prévision du chiffre d'affaires en terme de RMSE et MAE	54
5.13	Résultats obtenues par les trois modèles en comparaison (SARIMA, Holt-Winters et XGBoost) pour la prévision du nombre de clients en terme de RMSE et MAE	55
5.14	Description des visuels du tableau de bord "Segmentation des clients" . . .	60
5.15	Métriques d'évaluation des modèles	63
5.16	Comparaison des performances des deux modèles	64

Liste des acronymes

BIAT Banque Internationale Arabe de Tunisie

BI Business Intelligence

ETL Extract Transform Load

IT Information Technology

KPI Key Performance Indicator

SID Système d'Information Décisionnel

IFRS International Financial Reporting Standards

ADF Augmented Dickey-Fuller

XGBoost Extreme Gradient Boosting

SARIMA Seasonal AutoRegressive Integrated Moving Average

RMSE Root Mean Squared Error

MAE Mean Absolute Error

Introduction générale

Dans un environnement économique en constante évolution, la réussite des entreprises repose de plus en plus sur la maîtrise de l'information et la capacité à s'adapter rapidement aux changements. Pour rester compétitives, les organisations doivent mettre en place des stratégies de contrôle et de pilotage efficaces, en s'appuyant sur des outils capables de transformer les données en leviers décisionnels. La Business Intelligence (BI) s'impose aujourd'hui comme un élément clé de cette transformation. Elle permet aux entreprises d'analyser leurs données métiers, de suivre les indicateurs de performance (KPIs), d'évaluer les risques et de mieux comprendre le comportement de leurs clients. Grâce à des tableaux de bord dynamiques et des outils de visualisation, les décideurs disposent désormais d'une vision globale et synthétique de leur activité, facilitant des décisions éclairées et réactives. C'est dans cette optique que s'inscrit ce projet de fin d'études, réalisé au sein de l'assurance BIAT. Il vise à concevoir et à mettre en place un système d'information décisionnel, capable d'accompagner l'entreprise dans l'analyse de ses données liées au produit automobile. Le projet intègre la construction de tableaux de bord interactifs, la prévision d'indicateurs clés, ainsi que la segmentation et la prédiction du comportement des clients. Ce rapport est structuré comme suit :

- Le premier chapitre "Cadre général du projet", introduit l'environnement de travail au sein de l'assurance BIAT. Il expose les objectifs du projet, décrit l'existant, puis justifie la méthodologie adoptée en la comparant à d'autres approches pour la planification du projet.
- Le deuxième chapitre "Identification de l'environnement", présente en détail l'entreprise, son environnement ainsi que le produit assurance automobile.
- Le troisième chapitre "Conception", porte sur l'identification des exigences fonctionnelles et non fonctionnelles, la définition des KPIs, ainsi que les étapes essentielles ayant guidé la création des tableaux de bord.
- Le quatrième chapitre "Implémentation et audit", est dédié à l'implémentation technique. Il met en évidence les outils utilisés, décrit le processus ETL ainsi que les étapes de création des tableaux de bord interactifs.
- Le cinquième chapitre "Analyse avancée des données des clients de l'assurance BIAT : Prévision, segmentation et prédiction", présente la partie analytique avancée du projet. Il développe les modèles de prévision, de classification et de prédiction mis en œuvre pour anticiper le comportement des clients et appuyer la prise de décision stratégique.

L'ensemble de ces travaux vise à doter l'assurance BIAT d'un outil stratégique fondé sur les données, pour mieux anticiper les risques, suivre la performance et renforcer la relation avec ses clients.

Chapitre 1

Cadre général du projet

1.1 Introduction

Dans ce chapitre, nous visons à offrir une compréhension claire du périmètre du projet. Nous commencerons par une présentation générale, suivie d'une analyse des exigences spécifiques. Ensuite, nous exposerons les grandes lignes du projet et du stage, en étudiant l'existant, en identifiant les axes d'amélioration et en proposant des solutions aux défis rencontrés. Enfin, nous présenterons l'approche adoptée pour assurer une organisation structurée et efficace tout au long du projet.

1.2 Présentation de l'assurance BIAT

L'assurance BIAT est une filiale du groupe Banque Internationale Arabe de Tunisie (BIAT), spécialisée dans les assurances multibranches. Grâce à une stratégie axée sur l'innovation et une expertise solide, elle a connu une croissance continue en s'appuyant sur une équipe hautement qualifiée. Aujourd'hui, l'assurance BIAT dispose de 14 agences réparties sur le territoire Tunisien, ainsi que 3 centres d'expertise, offrant ainsi des services adaptés aux besoins variés des clients. La figure 1.1 montre le logo de l'assurance BIAT, représentant visuellement l'identité de l'entreprise.



FIGURE 1.1 : Logo de l'assurance BIAT [1]

1.2.1 Fiche signalétique

Le tableau 1.1 montre les principales informations administratives et juridiques de la compagnie d'assurance BIAT.

TABLEAU 1.1 : Fiche signalétique de l'assurance BIAT [1]

Dénomination	Assurances BIAT
Siège social	Immeuble Assurances BIAT – Les Jardins du Lac – Lac 2, 1053 Les Berges du Lac, Tunis
Date de création	Décembre 2002
Capital social	22 000 000 DT
Nombre d'actions	220 000 actions (valeur nominale : 100 DT chacune)
Origine	Tunisienne
Forme juridique	Société Anonyme (S.A) faisant appel public à l'épargne
Registre du commerce	B160631997
Matricule fiscal	0601492D
Contact	Tél : (+216) 31 300 100 / Fax : (+216) 71 197 810 / Email : contact@assurancesbiat.com.tn
Branches exploitées	Multibranches(Assurance vie, automobile, incendie, santé, etc.)

1.2.2 Organigramme hiérarchique de l'entreprise

La figure 1.2 illustre l'organigramme fonctionnel de la compagnie d'accueil, assurances BIAT. Au sommet de la hiérarchie se trouve la Direction Générale, appuyée par plusieurs départements stratégiques tels que le Département Actuariat et Risk Management, le Département Audit, Contrôle Permanent et Conformité, la Division Inspection et le Département Réassurance. L'organisation est structurée autour de six grands pôles : Le Pôle Assurances Dommages et Responsabilités, le Pôle Assurances de Personnes, le Pôle Commercial, le Pôle Comptabilité, Contrôle de Gestion et Recouvrement, le Pôle Systèmes d'Information, Transformation et Organisation, et enfin le Pôle Financier, Ressources Humaines, Logistique et Contentieux. C'est au sein du Pôle Comptabilité, Contrôle de Gestion et Recouvrement que se trouve le Département Budget et Contrôle de Gestion, mis en évidence sur la figure. Ce département, dans lequel mon stage a été effectué, joue un rôle clé dans la supervision et l'optimisation des performances financières de la compagnie. Il intervient dans l'élaboration des budgets, le suivi des KPIs, et l'analyse des écarts afin de proposer des ajustements opérationnels. Il contribue aussi à la définition des stratégies et à la conduite des plans d'action visant à améliorer l'efficacité et la rentabilité globale de l'entreprise.




FIGURE 1.2 : Organigramme de l'assurance BIAT [1]

1.2.3 Valeurs de l'assurance BIAT

L'assurance BIAT repose sur des valeurs fondamentales qui guident ses actions et ses décisions pour offrir des services d'assurance de qualité. Les valeurs de l'assurance BIAT être décrites comme suit [1] :

- Engagement client : Offrir des solutions adaptées aux besoins des assurés avec un accompagnement personnalisé.
- Excellence : Maintenir des standards élevés en matière de gestion des risques et de services financiers.
- Innovation : Intégrer des outils digitaux et des solutions intelligentes pour améliorer la gestion des contrats et des sinistres.
- Éthique et transparence : Assurer une communication claire avec les clients et partenaires pour une relation de confiance.
- Responsabilité sociale : Contribuer au développement économique et social en Tunisie à travers des solutions d'assurance adaptées.

1.2.4 Historique de l'assurance BIAT

L'assurance BIAT créée en décembre 2002. Depuis, elle a connu une évolution constante à travers l'expansion de ses services et l'innovation technologique, comme le montre le tableau 1.2.

TABLEAU 1.2 : Historique de l'assurance BIAT [1]

Année	Événement clé
2002	Fondation de l'assurance BIAT et intégration au groupe BIAT.
2005–2010	Expansion des services avec le lancement de nouvelles branches (auto, santé, habitation, etc.).
2015	Développement du secteur assurance vie grâce à la bancassurance en partenariat avec les agences BIAT.
2018	Digitalisation des services avec la mise en place de plateformes en ligne pour la gestion des contrats et sinistres.
2020	Adaptation post-COVID avec de nouveaux produits d'assurance pour les risques sanitaires et économiques.
2023	Introduction de l'intelligence artificielle et du machine learning pour améliorer la gestion des risques et clients.

1.2.5 Présentation du département contrôle de gestion

Mon stage a été effectué au sein du département contrôle de gestion d'assurance BIAT. Ce département joue un rôle central dans la supervision des performances financières, l'élaboration et le suivi budgétaire, le respect des normes comptables et réglementaires, ainsi que dans la réalisation de projets spécifiques à la demande de la direction générale. Ses principales activités peuvent être résumées comme suit :

- Élaboration et suivi budgétaire : Planification du budget de l'entreprise et alignement des prévisions financières avec les objectifs stratégiques.
- Suivi des performances financières : Analyse quotidienne du chiffre d'affaires afin de détecter les tendances, évaluer les écarts et ajuster les stratégies.
- Gestion des normes et de la réglementation : Étude de l'impact du passage aux normes International Financial Reporting Standards (IFRS) et suivi des exigences réglementaires pour garantir la conformité.
- Gestion de projets spécifiques : Prise en charge de projets ponctuels liés aux orientations stratégiques décidées par la direction générale [1].

1.3 Contexte du projet

Ce projet s'inscrit dans le cadre de la Licence Nationale en Business Computing, spécialité Business Intelligence (LNBC-BI) à l'Institut Supérieur de Gestion de Tunis (ISG-Tunis). Il a pour objectif de préparer les étudiants à la vie professionnelle en les confrontant à des problématiques réelles rencontrées en entreprise. Réalisé au sein d'une compagnie d'assurances spécialisée dans la gestion multibranche, ce stage a permis de concevoir une solution intégrant des volets décisionnels, prévisionnels, de segmentation et de prédiction du comportement des clients. Cette approche vise à valoriser les données disponibles afin de faciliter l'analyse, orienter les décisions stratégiques et anticiper les besoins ou les risques liés à la clientèle.

1.3.1 Analyse et critique de l'existant

Actuellement, l'entreprise d'accueil gère ses activités à l'aide d'outils internes et de systèmes d'information classiques. Les données sont collectées via des formulaires, saisies manuellement, puis stockées dans des bases dispersées entre plusieurs services. Les rapports de performance sont générés périodiquement, le plus souvent sous forme de fichiers Excel. Cette méthode de gestion présente plusieurs limites : L'absence de centralisation ralentit l'accès à l'information, le manque de normes freine l'analyse fiable de la rentabilité ou de la fidélité des clients, et aucun système n'est en place pour anticiper les évolutions futures. Pour répondre à ces défis, une solution complète a été conçue dans le cadre de ce projet, combinant plusieurs volets complémentaires : la création de tableaux de bord dynamiques pour une visualisation claire des KPIs, l'intégration de modèles de prévision pour anticiper les évolutions clés, la segmentation des clients pour mieux orienter les actions commerciales et de gestion des risques, ainsi que la prédiction du comportement des clients afin d'identifier en amont les profils à risque ou à fort potentiel. Cette approche offre à l'entreprise un outil d'aide à la décision efficace, favorisant un pilotage plus agile, une meilleure réactivité, et une amélioration globale de la stratégie opérationnelle.

1.3.2 Problématique

L'assurance BIAT ne dispose actuellement ni de tableaux de bord interactifs pour le suivi en temps réel de ses indicateurs clés, ni de modèles de prévision dynamiques permettant d'anticiper l'évolution de ces indicateurs. Elle ne bénéficie pas non plus de segmentation automatisée de ses clients assurés en assurance automobile, ni d'un système de prédiction de leur comportement. L'absence de ces outils freine la capacité de l'entreprise à analyser finement la rentabilité des contrats, à anticiper les risques ou les départs de ces assurés et à piloter efficacement ses actions commerciales. Ces lacunes limitent la prise de décision stratégique et nuisent à la performance globale dans un secteur de plus en plus concurrentiel.

1.3.3 Solution proposée

Pour accompagner la prise de décision au sein de l'assurance BIAT, nous proposons la mise en place d'un système décisionnel structuré, dédié à l'exploitation des données liées au produit automobile. Cette solution vise à combler les lacunes constatées, notamment l'absence de visualisations dynamiques, de prévisions fiables et d'outils d'analyse avancée. Elle permet d'améliorer significativement l'analyse des performances, la connaissance client et la gestion des risques. La démarche suivie repose sur les étapes suivantes :

- Collecte et centralisation des données clients et contrats issues de différentes sources internes, afin de construire une base de données unifiée, cohérente et exploitable ;
- Nettoyage, structuration et transformation des données pour garantir leur qualité et permettre des analyses précises et fiables ;
- Modélisation d'un data warehouse orienté assurance automobile, répondant aux besoins métiers spécifiques de la gestion des contrats, des sinistres et des performances clients ;
- Détermination des KPIs portant sur le chiffre d'affaires, la fidélité client, les pertes et gains générés, ainsi que le taux de résiliation ;
- Conception de tableaux de bord interactifs dans Power BI facilitant le suivi en temps réel de ces KPIs et permettant une lecture dynamique des tendances ;

- Intégration de modèles de prévision pour anticiper l'évolution des variables clés telles que le chiffre d'affaires, le taux de churn, le taux de fidélité et le nombre de contrats ;
- Segmentation des clients selon leur fidélité et leur ancienneté pour adapter les actions de fidélisation ou de prévention ;
- Mise en place d'un module de prédiction du comportement des clients permettant d'identifier les clients à risque de résiliation ou à fort potentiel ;
- Déploiement d'une interface de visualisation intégrée dans Power BI, regroupant tableaux de bord, prévisions, segmentations et prédiction pour soutenir une prise de décision rapide, proactive et orientée données.

1.4 Méthodologie de gestion du projet

La gestion efficace d'un projet nécessite l'adoption d'une méthodologie adaptée à ses besoins spécifiques. Dans le cadre de ce projet, nous avons étudié deux approches largement utilisées en BI : Scrum et GIMSI. Chacune présente des avantages et des inconvénients.

1.4.1 Méthodologie Scrum

Scrum est une approche agile qui repose sur un développement itératif et incrémental. Bien qu'elle soit principalement utilisée dans le développement logiciel, elle s'adapte également à d'autres types de projets nécessitant une grande flexibilité et une réactivité constante face aux changements. Elle se base sur des cycles courts appelés "sprints", avec des réunions quotidiennes et une réévaluation continue des priorités [2]. La figure 1.3 illustre de manière synthétique le processus de Scrum, en mettant en évidence les différentes étapes clés du product backlog au sprint backlog, en passant par le daily scrum meeting, jusqu'à la livraison de l'incrément de produit à la fin de chaque sprint.




FIGURE 1.3 : Processus de Scrum [2]

1.4.1.1 Avantages de Scrum

Scrum présente plusieurs avantages qui en font une méthode particulièrement adaptée aux projets décisionnels nécessitant agilité, réactivité et visibilité continue sur les KPIs. Ces avantages peuvent être résumés comme suit [3] :

- Flexibilité : S'adapte aux changements rapides et aux besoins évolutifs ;
- Améliore la collaboration : Encourage le travail d'équipe et la communication constante ;

- Livraisons fréquentes : Permet d’avoir des résultats progressifs à chaque sprint ;
- Réactivité aux imprévus : Facilité d’ajustement en cas de changement de priorités ;
- Implication des parties prenantes : Le client peut interagir régulièrement et donner son feedback ;
- Amélioration continue : Chaque sprint permet d’optimiser et d’améliorer le projet.

1.4.1.2 Limites de Scrum

Malgré ses nombreux avantages, la méthode Scrum présente certaines limites, notamment lorsqu’elle est appliquée à des projets décisionnels. Ces limites peuvent être résumées comme suit [4] :

- Dépendance à l’équipe : Nécessite une équipe bien formée et engagée pour être efficace ;
- Difficulté de planification : Pas de vision globale dès le départ, ce qui peut poser un problème dans un projet décisionnel ;
- Exigence de réunions fréquentes : Les daily stand-ups et les rétrospectives prennent du temps ;
- Risque de dérive : Sans une gestion rigoureuse, le projet peut dévier des objectifs initiaux.

1.4.2 Méthodologie GIMSI

GIMSI (*Goal-directed Iterative and Incremental Software Implementation*) est une méthodologie structurée spécifiquement conçue pour les projets décisionnels et les tableaux de bord en BI [5]. Elle suit un processus clair et organisé, représenté dans la figure 1.4.




FIGURE 1.4 : Processus GIMSI [5]

- **G : Généralisation** : Cette méthodologie peut être appliquée dans divers domaines.

- **I : Information** : L'obtention d'informations pertinentes est l'objectif principal en informatique décisionnelle.
- **M : Méthode et Mesure** : Grâce aux méthodes, il est possible de construire un système de contrôle efficace.
- **S : Système et Systémique** : La méthodologie permet d'intégrer le système de pilotage dans l'organisation et repose sur un concept systémique.
- **I : Individualité et Initiative** : Favorise la prise d'initiative et l'autonomie dans la gestion des projets. Elle est structurée en 10 étapes bien définies et classées en 4 phases principales, comme illustré dans la figure 1.4.
 1. Identification : Analyse du contexte et des objectifs stratégiques.
 - Étape 1 : Analyse de l'environnement de l'entreprise et définition du projet.
 - Étape 2 : Identification des processus et des acteurs impliqués.
 2. Conception : Définition des tableaux de bord et des KPIs.
 - Étape 3 : Définition des objectifs tactiques.
 - Étape 4 : Construction des tableaux de bord.
 - Étape 5 : Sélection des KPIs.
 - Étape 6 : Collecte et structuration des données.
 - Étape 7 : Conception du système de reporting.
 3. Implémentation : Mise en œuvre technique et intégration du système.
 - Étape 8 : Sélection et configuration du logiciel.
 - Étape 9 : Déploiement et intégration au sein de l'entreprise.
 4. Amélioration continue : Suivi et optimisation des performances.
 - Étape 10 : Audit et amélioration continue du tableau de bord.

1.4.2.1 Avantages de GIMSI

GIMSI présente plusieurs avantages qui justifient son utilisation dans le cadre de projets décisionnels. Ces avantages peuvent être résumés comme suit [6] :

- Conçu pour les projets décisionnels : Idéal pour les tableaux de bord et la gestion des KPIs ;
- Vision globale dès le départ : Planification structurée avec une roadmap définie ;
- Approche méthodique : Étapes bien définies, facilitant l'organisation du projet ;
- Meilleure gestion des indicateurs : Sélection rigoureuse des KPIs pour une meilleure analyse ;
- Adaptabilité aux entreprises : Peut être utilisé dans différents domaines nécessitant des tableaux de bord ;
- Fiabilité des données : Intègre des techniques de gestion et de validation des données.

1.4.2.2 Limites de GIMSI

Bien que GIMSI soit particulièrement adaptée aux projets décisionnels, elle présente certaines limites qu'il est important de prendre en compte. Ces inconvénients peuvent être résumés comme suit [7] :

- Moins flexible : Moins adapté aux changements rapides en cours de projet ;
- Implémentation plus longue : Nécessite du temps pour structurer et organiser les données ;

- Complexité méthodologique : Demande une bonne maîtrise des outils BI et de gestion des KPIs ;
- Exigeant en ressource : Nécessite des équipes spécialisées en analyse de données et reporting ;
- Approche rigide : Peu d’ajustements possibles en cours de projet une fois la structure définie.

1.4.2.3 Comparaison entre Scrum et GIMSI

Le tableau 1.3 présente une comparaison entre deux approches de gestion de projets Scrum et GIMSI. Cette comparaison se base sur plusieurs critères clés tels que le processus, la planification, l’objectif, l’adaptabilité et les limites. On remarque que Scrum est une méthode agile, itérative et très flexible, adaptée aux projets en constante évolution. En revanche, GIMSI suit une approche plus structurée avec une planification définie dès le début, ce qui le rend plus approprié pour des projets ayant des objectifs bien clairs et nécessitant une méthodologie rigoureuse.

TABLEAU 1.3 : Comparaison entre Scrum et GIMSI [8]

Critères	Scrum	GIMSI
Processus	Itératif et incrémental	Structuré en étapes bien définies
Planification	Début de chaque sprint	Plan dès le début
Objectif	Développement agile de logiciels	Conception de tableaux de bord
Adaptabilité	Forte flexibilité aux changements	Approche structurée et méthodique
Limites	Difficile à gérer pour les projets très cadrés	Moins flexible que Scrum pour les évolutions rapides

1.5 Méthodologie adoptée

Dans le cadre de ce projet, la méthodologie GIMSI a été utilisée, car elle s’avère parfaitement adaptée à la conception et à la mise en œuvre de systèmes décisionnels. Contrairement à Scrum, qui est une méthode agile généraliste principalement utilisée dans le développement logiciel, GIMSI est spécialement conçue pour répondre aux besoins spécifiques de la BI notamment la réalisation de tableaux de bord. Elle structure le projet autour d’étapes clés comme l’identification des besoins, la définition des KPIs, la modélisation des données et la validation des livrables avec les utilisateurs. GIMSI offre ainsi un cadre méthodologique rigoureux, centré sur les objectifs décisionnels et la fiabilité des données, ce qui est essentiel dans un contexte comme celui de l’assurance BIAT. De plus, cette entreprise ne suit pas de méthodologie agile telle que Scrum dans ses processus internes, ce qui renforce la pertinence du choix de GIMSI pour garantir la cohérence, l’efficacité et la réussite du projet.

1.6 Planification du projet

La planification des différentes étapes du projet a été structurée à l'aide d'un diagramme de Gantt, présenté dans la figure 1.5. Ce diagramme permet de visualiser de manière chronologique l'ensemble des tâches réalisées, depuis l'analyse du besoin jusqu'au déploiement de la solution finale. Il permet également de suivre l'avancement du projet, d'identifier les périodes critiques et de garantir une gestion efficace du temps et des ressources mobilisées.




FIGURE 1.5 : Diagramme de Gantt représentant la planification du projet

1.7 Conclusion

En conclusion, ce chapitre a mis en lumière les limites du système actuel de gestion des données chez l'assurance BIAT. Pour y répondre, une démarche complète a été proposée, intégrant des outils de BI, de prévision, de segmentation et de prédiction. La méthodologie GIMSI a été choisie pour structurer le projet et guider sa mise en œuvre. Le chapitre suivant portera sur l'analyse de l'environnement de l'entreprise afin d'identifier ses besoins réels.

Chapitre 2

Identification de l'environnement

2.1 Introduction

Ce chapitre propose une analyse approfondie de l'écosystème organisationnel de l'assurance BIAT, en examinant son modèle économique, ses processus et ses principaux acteurs. Grâce à une approche méthodique, nous visons à mieux comprendre le contexte global de l'entreprise et ses interactions avec les influences externes. Cette analyse détaillée permettra d'apporter des éclairages pertinents, d'orienter le développement des stratégies et de proposer des recommandations pour l'optimisation et l'expansion des activités.

2.2 Environnement de l'entreprise

L'assurance BIAT, acteur majeur du secteur des assurances en Tunisie, gère un large éventail de produits et services visant à répondre aux besoins diversifiés de ses clients. Grâce à une expertise approfondie et à une approche axée sur l'innovation, elle a mis en place plusieurs initiatives et solutions clés :

- Assurance auto : Une couverture complète pour protéger les véhicules des particuliers et des entreprises contre divers risques (accidents, vol, incendie, responsabilité civile) ;
- Assurance santé : Une protection adaptée aux besoins des assurés, incluant des garanties pour les soins médicaux, hospitaliers et pharmaceutiques ;
- Assurance vie et prévoyance : Des solutions d'épargne et de prévoyance visant à garantir la sécurité financière des assurés et de leurs bénéficiaires ;
- Assurance habitation : Une protection contre les risques liés au domicile, incluant les catastrophes naturelles, incendies et vols ;
- Assurance voyage : Un service d'assistance et de couverture pour les frais médicaux et imprévus lors des déplacements à l'étranger ;
- BIAT assistance : Un service d'assistance rapide et personnalisé en cas de sinistre ou d'urgence, disponible pour les clients nécessitant une prise en charge immédiate ;
- Digitalisation des services : Un portail client en ligne permettant aux assurés de gérer leurs contrats, déclarer des sinistres et suivre leurs remboursements en toute autonomie ;
- Gestion des risques : Un système analytique permettant d'optimiser l'évaluation des risques et d'adapter les stratégies de tarification et de prévention.

Grâce à ces services, l'assurance BIAT renforce sa position sur le marché et continue d'innover pour offrir une meilleure expérience client tout en améliorant la gestion des

sinistres et des contrats.

2.3 Processus de l'assurance BIAT

L'assurance BIAT est une compagnie d'assurance Tunisienne qui propose une gamme complète de solutions adaptées aux besoins des particuliers et des entreprises. Elle repose sur un ensemble de processus visant à optimiser la gestion des contrats, la prise en charge des sinistres et l'amélioration de l'expérience client. Grâce à une approche innovante et digitalisée, l'assurance BIAT met en œuvre des solutions performantes pour garantir une couverture efficace et un suivi optimal des assurés [1].

2.4 Établissements de l'assurance BIAT

L'assurance BIAT s'appuie sur un ensemble d'établissements répartis sur le territoire tunisien pour assurer le bon fonctionnement de ses activités. En plus de ses 14 agences commerciales, elle dispose de :

- 3 centres d'expertise automobile : Chargés de l'évaluation des sinistres liés aux véhicules assurés. Ces centres permettent une gestion rapide, fiable et centralisée des dommages matériels ;
- 1 siège social : Situé aux Jardins du Lac 2 à Tunis, il regroupe les services de direction, les départements stratégiques (contrôle de gestion, actuariat, informatique, etc.) et les équipes de support ;
- Services techniques et de gestion : Répartis entre les unités centrales à Tunis et les agences, ils assurent la gestion quotidienne des contrats, la relation client, les indemnisations et la conformité réglementaire ;

Ce maillage d'établissements permet à l'assurance BIAT de garantir un service de proximité, tout en maintenant une structure centralisée pour la coordination stratégique et la qualité de gestion.

2.5 Activités de l'assurance BIAT

L'assurance BIAT propose plusieurs activités détaillées ci-dessous :

- Gestion des sinistres : L'assurance BIAT met en place un système de gestion des sinistres permettant un traitement rapide et efficace des déclarations. L'objectif est d'optimiser le délai de prise en charge et de garantir un remboursement fluide et transparent pour les assurés ;
- Assurance vie et prévoyance : L'entreprise offre une gamme complète de solutions de prévoyance et d'épargne adaptées aux besoins des particuliers et des entreprises. Ces produits visent à sécuriser l'avenir des assurés en leur offrant une protection financière en cas d'imprévu ;
- Assurance automobile : Un large éventail de couvertures est proposé, allant de la responsabilité civile obligatoire aux assurances tous risques, permettant aux clients de protéger efficacement leurs véhicules et de bénéficier d'une assistance en cas d'accident ;
- Assurance santé : L'assurance BIAT propose des contrats adaptés aux besoins de ses clients, couvrant les frais médicaux, hospitaliers et pharmaceutiques. Des

solutions sur-mesure sont mises en place pour répondre aux attentes des particuliers et des entreprises ;

- Assurance habitation et multirisque : Cette offre permet de protéger les biens immobiliers contre divers risques tels que l'incendie, le vol, les dégâts des eaux et les catastrophes naturelles ;
- Digitalisation et portail client : L'assurance BIAT investit dans la digitalisation de ses services afin d'améliorer l'expérience client. Un portail en ligne permet aux assurés de gérer leurs contrats, de déclarer leurs sinistres et de suivre leurs remboursements en temps réel ;
- Formation et sensibilisation : L'assurance BIAT propose des programmes de formation et de sensibilisation à destination de ses agents et partenaires afin de renforcer leurs compétences en matière de gestion des risques, de conseil client et de conformité réglementaire ;
- Coaching et accompagnement : Un service d'accompagnement personnalisé est proposé aux entreprises et aux professionnels souhaitant optimiser leur couverture et mieux gérer leurs risques. L'assurance BIAT offre des conseils stratégiques pour améliorer la gestion des contrats et la relation client ;
- Assistance et services complémentaires : Un service d'assistance est disponible 24h/24 et 7j/7 pour aider les assurés en cas de sinistre ou d'urgence. Des prestations complémentaires, telles que l'expertise des dommages et l'indemnisation rapide, sont mises en place pour garantir une satisfaction optimale.

Grâce à ces différentes activités, l'assurance BIAT s'engage à offrir des solutions adaptées aux besoins de ses clients tout en assurant un service de qualité et en innovant continuellement pour s'adapter aux évolutions du marché [1].

2.6 Les acteurs de l'assurance BIAT

L'assurance BIAT repose sur l'implication de plusieurs acteurs aux profils variés, chacun jouant un rôle déterminant dans le bon fonctionnement de l'écosystème assurantiel. Voici les principaux intervenants :

- Clients : Les particuliers et les entreprises souscrivant aux produits d'assurance (auto, santé, vie, habitation, etc.). Ils sont les principaux bénéficiaires des services offerts et interagissent directement avec la compagnie pour la gestion de leurs contrats et sinistres ;
- Courtiers et agents d'assurance : Professionnels chargés de conseiller les clients et de leur proposer les solutions d'assurance les mieux adaptées à leurs besoins. Ils jouent un rôle clé dans la distribution des produits et la fidélisation des assurés ;
- Experts en sinistres : Spécialistes chargés d'évaluer les dommages en cas de sinistre et de déterminer les indemnisations appropriées. Ils assurent une gestion transparente et efficace des déclarations ;
- Organismes de régulation : Institutions comme la commission de supervision des assurances ou les autorités financières, chargées de veiller à la conformité des pratiques de l'assurance BIAT avec la réglementation en vigueur ;
- Professionnels de la santé : Médecins, hôpitaux et cliniques partenaires qui collaborent avec l'assurance BIAT dans le cadre des assurances santé pour offrir des prestations médicales aux assurés ;
- Développeurs et analystes en data science : Experts en informatique et en analyse de données qui participent à la digitalisation des services, à l'amélioration des outils

d'aide à la décision et à l'optimisation de la gestion des risques ;

- Gestionnaires et personnel administratif : Employés de l'assurance BIAT qui assurent la gestion des contrats, le suivi des clients et le bon fonctionnement des opérations internes.

2.7 Les garanties de l'assurance automobile

L'assurance automobile est un contrat qui protège le conducteur et son véhicule contre les risques liés à la circulation (accidents, vol, incendie, etc.). Elle permet de rouler en toute tranquillité, en prenant en charge les dommages causés à autrui ou au véhicule assuré selon la formule choisie (standard, collision ou tous risques) [1]. L'assurance BIAT propose trois formules modulables d'assurance automobile, adaptées aux besoins variés de ses clients — particuliers comme professionnels. Ces formules offrent une panoplie de garanties allant de la couverture minimale obligatoire à une protection complète du véhicule assuré.

- Formule standard : Couvre les garanties de base comme la responsabilité civile, l'incendie, le vol, et certaines protections juridiques ;
- Formule collision : Inclut les garanties de la formule standard avec des options supplémentaires comme le bris de glace ou les dommages collision ;
- Formule tous risques : Offre la couverture la plus complète avec prise en charge des dommages au véhicule assuré, forces de la nature, bonus en cas de non-sinistre, etc.

Les trois formules proposées par l'assurance BIAT se distinguent par le niveau de couverture qu'elles offrent. Le tableau 2.1 présente une comparaison claire des garanties incluses dans chaque formule :

TABLEAU 2.1 : Comparatif des garanties selon les formules d'assurance auto proposées par BIAT [1]

Garanties principales	Standard	Collision	Tous Risques
Responsabilité civile	Oui	Oui	Oui
Incendie	Oui	Oui	Oui
Vol	Oui	Oui	Oui
Défense et recours	Oui	Oui	Oui
Conducteur +	Oui	Oui	Oui
PTA (Personnes transportées à titre gratuit)	Option	Option	Option
Assistance	Oui	Oui	Oui
AAA (Assistance Accident Auto)	Oui	Oui	Oui
Bris de glace	Non	Oui	Oui
Bris isolé des optiques avant	Non	Oui	Non
Dommages collision	Non	Oui	Non
Dommages au véhicule assuré	Non	Non	Oui
Forces de la nature (inondation, grêle...)	Non	Option	Oui
Avance sur frais de réparation	Non	Non	Oui
Véhicule de remplacement	Non	Non	Oui
Bonus en cas de non-sinistre	Non	Non	Oui

- **Avantages spécifiques à la formule Standard :**
 - Garanties de base à un tarif accessible ;
 - Couverture des dommages aux tiers ;
 - Protection du conducteur incluse ;
 - Assistance en cas de panne ou accident ;
 - Option : Couverture des personnes transportées à titre gratuit.
- **Avantages spécifiques à la formule Collision :**
 - Toutes les garanties de la formule standard ;
 - Bris de glace et bris isolé des optiques avant couverts ;
 - Dommages collision pris en charge ;
 - Option : couverture contre les forces de la nature (inondation, grêle, etc.) ;
 - Option : Véhicule de remplacement.
- **Avantages spécifiques à la formule Tous Risques :**
 - Avance financière pour la réparation du véhicule ;
 - Véhicule de remplacement pris en charge ;
 - Bonus en cas de non-sinistre.

2.8 Conclusion

Ce chapitre nous a permis de découvrir l'assurance BIAT, une entreprise qui joue un rôle clé dans le secteur des assurances en proposant des solutions adaptées aux besoins des particuliers et des entreprises. En comprenant son approche stratégique et son engagement envers l'innovation, nous pouvons concevoir un tableau de bord décisionnel capable de répondre aux exigences techniques du secteur, tout en facilitant la gestion des risques, la prévision de l'évolution des indicateurs clés, et l'anticipation des comportements clients. Cette approche permet à l'assurance BIAT de renforcer sa performance globale et de soutenir une démarche d'amélioration continue.

Chapitre 3

Conception

3.1 Introduction

La phase de conception de la méthode GIMSI joue un rôle essentiel dans le développement d'un système de tableau de bord pour un entrepôt de données. À l'image de la planification d'un bâtiment, cette étape permet de définir clairement les objectifs du tableau de bord, tant sur le plan fonctionnel (Exigences fonctionnelles) que non fonctionnel (Exigences non fonctionnelles). Elle implique le choix des indicateurs clés, la collecte d'informations et la mise en place d'un système aligné sur les objectifs de l'entreprise. Ce chapitre explore ces éléments en soulignant leur importance pour la performance du tableau de bord.

3.2 Définition des principales exigences

Dans cette section, nous examinerons à la fois les exigences fonctionnelles et non fonctionnelles afin de mieux comprendre les besoins du projet.

3.2.1 Exigences fonctionnelles

Les exigences fonctionnelles définissent l'ensemble des services attendus par les utilisateurs finaux afin d'assurer une exploitation optimale des données issues de l'assurance automobile. Elles incluent :

- La création de tableaux de bord interactifs pour analyser des clients, des contrats, et les performances des agences ;
- La mise en place de filtres dynamiques permettant d'explorer les indicateurs clés selon différentes dimensions ;
- L'intégration de visualisations de prévision pour anticiper l'évolution de certains indicateurs stratégiques ;
- La conception d'un tableau de bord dédié à la segmentation des clients selon des critères de comportement et de fidélité ;
- La mise en place d'une interface prédictive, sous forme de chatbot intelligent, permettant d'estimer le comportement futur d'un client à partir de ses données historiques.

3.2.2 Exigences non fonctionnelles

Une fois les exigences fonctionnelles satisfaites, il est essentiel de prendre en compte les exigences non fonctionnelles tout au long du développement du projet. Ces exigences définissent les standards internes du produit final. Parmi elles, on trouve :

- Efficacité : Le système doit garantir des temps de réponse rapides, que ce soit lors du chargement des tableaux de bord ou de l'utilisation des filtres dynamiques ;
- Lisibilité : Les interfaces graphiques doivent être homogènes, bien organisées et facilement compréhensibles par les utilisateurs, même sans expertise technique ;
- Ergonomie : La navigation doit être fluide et intuitive, avec un agencement clair des KPIs, segments et filtres ;
- Simplicité : Les visualisations doivent être accessibles à tous les profils d'utilisateurs, avec une logique de lecture claire et sans surcharge d'informations ;
- Performance : L'ensemble du système doit pouvoir gérer un volume important de données (contrats, clients, historiques, etc.) sans ralentissement ni erreur d'affichage ;
- Fiabilité des résultats : Les modèles de prévision, de segmentation et de prédiction doivent s'appuyer sur des données nettoyées et validées pour garantir la cohérence des résultats affichés ;
- Réactivité : Les temps de réponse pour la génération des prédictions doivent être courts, même avec de grandes bases de données ;
- Adaptabilité : Les résultats des analyses prédictives doivent pouvoir s'actualiser facilement en fonction des filtres ;
- Accessibilité intelligente : Le chatbot prédictif intégré doit être simple d'utilisation ;
- Clarté des interprétations : Les segments clients et les prévisions doivent être affichés de manière visuelle et lisible.

3.3 Construction du tableau de bord

Dans cette phase, nous explorons le concept de tableau de bord décisionnel en mettant l'accent sur son rôle au sein de l'assurance BIAT. La création d'un tableau de bord consiste à concevoir une interface visuelle permettant de présenter les KPIs et les données essentielles de manière claire, synthétique et accessible. L'objectif est d'offrir aux équipes de l'assurance BIAT un outil efficace pour visualiser, analyser et suivre l'évolution des données relatives aux contrats, aux clients et aux performances des agences, tout en facilitant la prise de décision stratégique. La mise en place de ces tableaux de bord implique la sélection de sources de données fiables, la conception de visualisations adaptées aux différents besoins métiers, ainsi que la configuration d'une interface intuitive répondant aux attentes spécifiques de l'entreprise en matière de gestion des activités et de pilotage.

3.3.1 Présentation du tableau de bord

Le tableau de bord constitue un outil central de pilotage, permettant de suivre en temps réel l'avancement des activités et de visualiser les indicateurs clés liés aux performances. Il offre aux parties prenantes une représentation synthétique et dynamique des données essentielles du projet, facilitant l'évaluation des résultats, la détection des écarts et la mise en œuvre d'actions correctives. Ce tableau permet de centraliser les informations, de garantir une communication cohérente entre les équipes, et de prendre des décisions

rapides basées sur des données à jour. Cette section met en lumière l'intérêt stratégique de construire un tableau de bord efficace en gestion de projet, tout en détaillant ses principales étapes de conception et les bénéfices qu'il peut apporter à l'organisation[9].

3.3.2 Importance de la construction d'un tableau de bord

La mise en place d'un tableau de bord constitue un élément stratégique dans le secteur des assurances, où le suivi rigoureux des indicateurs est essentiel pour assurer une gestion efficace des contrats, des risques et des performances globales. À l'assurance BIAT, ces outils décisionnels offrent une vision claire en temps réel des activités clés et permettent aux décideurs de piloter avec précision les différentes dimensions de l'entreprise. Voici les principaux avantages apportés par l'utilisation d'un tableau de bord décisionnel :

- Améliorer la visibilité et la transparence : Le tableau de bord centralise les données, facilitant ainsi l'évaluation rapide des performances commerciales ou du taux de fidélité. Cette transparence est un atout majeur dans un secteur aussi réglementé que l'assurance ;
- Optimiser la prise de décision basée sur les données : En s'appuyant sur des indicateurs clés fiables, les responsables peuvent anticiper les tendances, ajuster les stratégies de renouvellement ou de prévention, et réagir rapidement face à tout changement ;
- Renforcer la gestion des risques : Un tableau de bord bien conçu aide à détecter les anomalies, à suivre les sinistres en temps réel et à mettre en place rapidement des mesures correctives pour limiter leur impact.

En conclusion, l'intégration de tableaux de bord décisionnels chez l'assurance BIAT représente un levier fondamental de performance. En améliorant la transparence, la réactivité et la précision des analyses, ces outils contribuent à une gestion plus stratégique, proactive et orientée client. Ils permettent notamment un meilleur suivi des contrats automobiles, une anticipation des comportements assurés, et un pilotage global plus efficace [9].

3.4 Collecte des informations

L'extraction des données joue un rôle crucial dans le processus d'intégration des informations, constituant la base de toute analyse ultérieure. Elle consiste à collecter des données issues de diverses sources telles que les bases de données, les feuilles de calcul et les fichiers texte. Une fois extraites, ces données sont converties dans un format homogène et exploitable, facilitant ainsi leur analyse et permettant d'en tirer des informations précieuses. Ces données sont essentielles pour prendre des décisions éclairées et améliorer la performance globale d'une entreprise.

3.5 Sélection des indicateurs

La sélection des KPIs a été réalisée en collaboration avec l'encadrant académique et les experts métiers de l'assurance BIAT. Cette démarche a permis d'identifier les indicateurs les plus pertinents pour trois volets d'analyse : L'analyse des clients, l'analyse des contrats et l'analyse des agences. Les indicateurs sélectionnés couvrent plusieurs dimensions essentielles à la prise de décision, notamment la performance commerciale, la fidélisation des

clients, l'atteinte des objectifs stratégiques ainsi que l'analyse géographique. Les différents indicateurs sont présentés dans les tableaux suivants :

- Le tableau 3.2 regroupe les indicateurs liés à l'analyse des clients. Il présente une vue d'ensemble sur la structure et le comportement de la clientèle, en mettant en évidence le nombre total de clients, les anciens clients, les nouveaux clients acquis, ainsi que leur impact sur le chiffre d'affaires global. Il intègre également des KPIs essentiels tels que le taux de churn, le taux de fidélité et le taux de renouvellement, permettant d'évaluer la qualité de la relation client et la stabilité du portefeuille.
- Le tableau 3.3 regroupe les indicateurs liés à l'analyse des contrats. Il permet de suivre l'évolution du volume de contrats à travers les renouvellements, les résiliations et les nouvelles souscriptions. Ce tableau met également en évidence la contribution de chaque catégorie de contrat au chiffre d'affaires, en différenciant le total généré par les renouvellements et celui généré par les nouveaux contrats. Il sert ainsi à évaluer la dynamique commerciale de l'entreprise.
- Le tableau 3.4 contient les indicateurs liés à l'analyse des agences. Il fournit une vision consolidée de la performance des agences en mesurant des éléments tels que le nombre total d'agences, le chiffre d'affaires généré par chacune, et le nombre de clients qu'elles gèrent. Ces indicateurs sont essentiels pour comparer les performances régionales et optimiser la gestion du réseau d'agences.

TABLEAU 3.2 : Liste des KPI pour l'analyse des clients

Indicateur	Description
Nombre_Total_Clients	Nombre total de clients.
Nombre_Anciens_Clients	Nombre d'anciens clients.
Nouveaux_Clients	Nombre de nouveaux clients.
Total_CA	Total du chiffre d'affaires.
Total_CA_perdus	Chiffre d'affaires perdu suite aux départs clients.
Taux_Churn	Pourcentage de clients perdus par rapport au nombre total de clients.
Taux_Fidelite	Pourcentage de clients fidèles par rapport au nombre total de clients.
Taux_Renouvellement	Pourcentage d'anciens clients qui ont renouvelé.

TABLEAU 3.3 : Liste des KPI pour l'analyse des contrats

Indicateur	Description
Nombre_Total_Contrats	Nombre total de contrats.
Nombre_Contrats_Renouveles	Nombre total de contrats renouvelés.
Nombre_Contrats_Resilies	Nombre total de contrats résiliés.
Nombre_Nouveaux_Contrats	Nombre total de nouveaux contrats.
Total_CA_Contrats_Renouveles	Total du chiffre d'affaires des contrats renouvelés.
Total_CA_Nouveaux_Contrats	Total du chiffre d'affaires des nouveaux contrats.

TABLEAU 3.4 : Liste des KPI pour l'analyse des agences

Indicateur	Description
Nombre_Total_Agences	Nombre total d'agences.
Chiffre_Affaire_Agence	Chiffre d'affaires par agence.
Nombre_Clients_Par_Agence	Nombre de clients par agence.

EXERCICE	TMP_MONTH	TMP_TYPE	CTMP_POL_EXT_CDE	TMP_AGENT_CDE	TMP_CLIENT_CDE	CATEGORIE_CLIE CA	CONTRAT_TYPE	SOURCE_ANI	TMP_AGENT_RÉGION	Perte
2020	1	A	101050005912	100	108705	Personne physiq-364.65	Ancien contrat	2020	Bureau Direc Tunis	364.65
2020	1	T	101180000054	701	106538	Personne physiq-686.575	Ancien contrat	2020	Agence Arian Ariana	0.0
2020	1	T	101190000176	100	107850	Personne physiq-2314.844	Ancien contrat	2020	Bureau Direc Tunis	0.0
2020	1	T	101050003138	700	104607	Personne physiq-359.35	Ancien contrat	2020	Agence Tunis Tunis	0.0
2020	1	T	101160000559	712	102381	Personne physiq-398.68	Ancien contrat	2020	Agence Sfax (Sfax)	0.0
2020	1	C	101200000192	105005	103621	Personne physiq-1756.534	Nouveau contrat	2020	Bureau Direc Tunis	0.0
2020	1	T	101100001203	700	100303	Personne physiq-541.433	Ancien contrat	2020	Agence Tunis Tunis	0.0
2020	1	T	101080000802	100	101318	Personne physiq-345.05	Ancien contrat	2020	Bureau Direc Tunis	0.0
2020	1	A	101120000202	100	98929	Personne physiq-488.45	Ancien contrat	2020	Bureau Direc Tunis	488.45
2020	1	T	101060001118	700	96723	Personne physiq-472.039	Ancien contrat	2020	Agence Tunis Tunis	0.0
2020	1	T	101160000669	712	96480	Personne physiq-1623.435	Ancien contrat	2020	Agence Sfax (Sfax)	0.0
2020	1	T	101100001529	712	97456	Personne physiq-301.8	Ancien contrat	2020	Agence Sfax (Sfax)	0.0
2020	1	C	101160005575	706	94687	Personne physiq-40.0	Ancien contrat	2020	Agence Nabe Nabeul	0.0
2020	1	T	101120000015	100	95493	Personne physiq-463.65	Ancien contrat	2020	Bureau Direc Tunis	0.0
2020	1	T	101170000198	706	94488	Personne physiq-1625.695	Ancien contrat	2020	Agence Nabe Nabeul	0.0
2020	1	C	101200000218	712	93081	Personne physiq-157.0	Nouveau contrat	2020	Agence Sfax (Sfax)	0.0
2020	1	T	101100000927	288	92464	Personne physiq-401.23	Ancien contrat	2020	Bureau Direc Tunis	0.0
2020	1	T	101190000174	700	89846	Personne physiq-579.22	Ancien contrat	2020	Agence Tunis Tunis	0.0

FIGURE 3.1 : Extrait du fichier Excel contenant les données contractuelles de BIAT Assurance

Pour construire un entrepôt de données efficace, il est essentiel de bien comprendre les données disponibles. C'est pourquoi nous avons opté pour une méthode d'extraction complète, consistant à récupérer l'ensemble des tables depuis la source, comme illustré dans la figure 3.1.

3.6 Système de tableaux de bord

Dans cette section, nous examinerons de plus près divers schémas d'entrepôt de données, analyserons différentes approches de conception d'un entrepôt de données et explorerons leurs concepts.

3.6.1 Approches de conception d'entrepôt de données

Les méthodologies d'Inmon et de Kimball sont parmi les plus couramment utilisées pour structurer les entrepôts de données. Chacune offre des avantages distincts et est adaptée à des besoins organisationnels spécifiques. Comprendre ces méthodologies est crucial pour concevoir une solution d'entrepôt de données efficace, alignée sur les objectifs de l'entreprise et facilitant une gestion efficiente des données. Maîtriser ces approches est fondamental pour élaborer un entrepôt de données performant, adapté aux besoins de l'entreprise et facilitant une gestion efficiente de l'information.

3.6.1.1 Approche Inmon

L'approche proposée par Bill Inmon, considéré comme un pionnier de l'informatique décisionnelle, repose sur une vision centralisée du stockage des données. Connue sous le nom d'approche *top-down*, qui consiste à construire un entrepôt de données global dès le départ, en intégrant toutes les données dans une structure unifiée. Le tableau 3.5 présente un récapitulatif des principales caractéristiques de l'approche Inmon, ainsi que ses avantages

TABLEAU 3.5 : Approche Inmon [10]

Caractéristiques	Avantages	Limites
L'entrepôt de données d'entreprise est construit en premier, puis les datamarts sont créés à partir de celui-ci.	Fournit une vue complète et centralisée des données de toute l'entreprise.	Le développement initial est long et nécessite des ressources importantes.
Les données sont organisées selon un modèle relationnel structuré, sans redondance.	Assure une meilleure qualité et cohérence des données.	Les requêtes peuvent être plus complexes à écrire et plus lentes à exécuter.
L'entrepôt intègre toutes les données provenant de différents services.	Favorise une source unique et fiable d'information.	Moins de flexibilité pour répondre rapidement aux besoins spécifiques des utilisateurs.
Les datamarts sont alimentés depuis l'entrepôt principal et non de manière indépendante.	Assure l'uniformité des informations entre les départements.	Moins adapté pour une mise en œuvre rapide ou pour les petites structures.
L'approche est conçue pour répondre aux besoins globaux de l'organisation.	Permet une évolution progressive et structurée du système d'information décisionnel.	Moins centrée sur les utilisateurs finaux ou les besoins immédiats.

tels que la cohérence des données et sa vision globale, mais aussi ses limites, notamment le coût initial élevé et la complexité de mise en œuvre.

3.6.1.2 Approche Kimball

Développée par Ralph Kimball, l'approche *bottom-up* consiste à construire l'entrepôt de données à partir de data marts indépendants, chacun centré sur une fonction métier. Ceux-ci sont ensuite intégrés pour former un système décisionnel global. Cette méthode se distingue par sa flexibilité, sa mise en œuvre rapide et son orientation métier. Le tableau 3.6 en résume les principales caractéristiques, avantages (simplicité, implication des utilisateurs) et limites (risque de redondance, absence de vision centralisée).

3.6.1.3 Comparaison des approches Inmon et Kimball

Le tableau 3.7 compare les deux approches principales de conception d'entrepôts de données, Inmon et Kimball, en mettant en évidence leurs différences clés sur plusieurs aspects.

3.6.1.4 Approche adoptée

Après avoir analysé les besoins, les contraintes et les caractéristiques de notre organisation, nous avons choisi d'adopter l'approche Kimball. Ce choix s'explique par notre volonté de construire l'architecture décisionnelle de manière progressive, en commençant par des datamarts ciblés, faciles à développer, à maintenir et à faire évoluer. Cette méthode est mieux adaptée à notre contexte, dans lequel la flexibilité, l'agilité et l'implication métier sont essentielles pour le succès du projet décisionnel.

TABLEAU 3.6 : Approche Kimball [11]

Caractéristiques	Avantages	Limites
L'entrepôt de données est construit progressivement en partant des besoins spécifiques des départements.	Mise en œuvre rapide pour répondre aux besoins immédiats des utilisateurs.	Peut entraîner une vision fragmentée des données au niveau de l'entreprise.
Utilisation de modèles dimensionnels simples, tels que le schéma en étoile.	Facilité de compréhension et d'utilisation pour les utilisateurs métiers.	Risque de redondance des données entre les différents data marts.
Intégration des données à partir de différents systèmes sources via des processus ETL.	Flexibilité pour intégrer de nouvelles sources de données au fil du temps.	Complexité accrue dans la gestion des processus ETL à mesure que le système évolue.
Conception orientée vers les besoins analytiques des utilisateurs finaux.	Amélioration de la prise de décision grâce à des analyses ciblées.	Moins adapté pour une vue d'ensemble centralisée des données de l'entreprise.
Approche itérative permettant des ajustements en fonction des retours des utilisateurs.	Capacité à s'adapter rapidement aux changements des besoins métiers.	Nécessite une coordination étroite entre les équipes pour maintenir la cohérence des données.

TABLEAU 3.7 : Comparaison entre les approches Inmon et Kimball [11]

Aspect	Approche Inmon	Approche Kimball
Philosophie et méthodologie	Centralisée, descendante et construite autour d'un modèle de données global.	Décentralisée, ascendante et basée sur des data marts spécialisés intégrés.
Intégration des données	Standardisation et nettoyage poussés avant intégration des données.	Intégration minimale, données chargées directement dans les data marts.
Qualité des données	Haute qualité assurée par un contrôle centralisé.	Bonne qualité mais plus ciblée selon les besoins métiers.
Flexibilité	Peu flexible et difficilement modifiable après mise en place.	Très flexible, facilement évolutive et adaptable.
Temps et ressources	Mise en place lente et coûteuse.	Déploiement rapide et peu coûteux.
Adaptabilité organisationnelle	Idéale pour les grandes structures complexes.	Parfaite pour les entreprises dynamiques ou à ressources limitées.

3.6.2 Schémas d'entrepôt de données

Un schéma dans le contexte d'un entrepôt de données joue un rôle similaire à un plan d'architecte pour une base de données. Il définit les différents types d'enregistrements, les données qu'ils contiennent ainsi que les relations entre eux. Contrairement aux bases de

données relationnelles classiques, les entrepôts de données utilisent généralement l'un des trois principaux types de schémas : Le schéma en étoile, le schéma en flocon et le schéma en constellation de faits. Ces schémas permettent d'organiser les données de manière optimale pour l'analyse décisionnelle. Dans cette section, nous présentons les trois modèles :

3.6.2.1 Schéma en étoile

Le schéma en étoile est l'un des modèles les plus simples et les plus couramment utilisés dans les entrepôts de données [12]. Il se compose d'une table de faits centrale, reliée à plusieurs tables de dimensions, formant ainsi une structure en étoile comme illustré dans la figure 3.2. La table de faits contient des mesures quantitatives telles que le total du chiffre d'affaires, le nombre total des contrats, le nombre total des clients, etc. Les tables de dimensions, quant à elles, décrivent le contexte des données en apportant des informations sur le temps, les régions, les clients ou les agences.

— **Avantages du schéma en étoile :**

- Simplicité de conception : Facile à comprendre et à mettre en œuvre, ce qui en fait un choix privilégié pour les projets décisionnels ;
- Performance des requêtes : Les requêtes sont rapides, car elles ne nécessitent que peu de jointures (entre la table de faits et quelques dimensions) ;
- Facilité de maintenance : La structure est simple à maintenir, ce qui réduit le coût global de gestion.

— **Limites du schéma en étoile :**

- Redondance des données : Les tables de dimensions peuvent contenir des informations dupliquées ;
- Moins adapté aux modèles complexes : Pour les structures très détaillées ou hiérarchiques, le modèle peut manquer de finesse et générer des performances moindres.




FIGURE 3.2 : Illustration du schéma en étoile [13]

3.6.2.2 Schéma en flocon de neige

Le schéma en flocon est une version étendue du schéma en étoile, conçue pour modéliser des structures de données plus complexes. Comme dans le modèle précédent, une table de faits est reliée à des tables de dimensions (voir figure 3.3). Cependant, dans le schéma en

flocon de neige, les tables de dimensions sont normalisées en plusieurs sous-tables reliées entre elles. Cette structure donne au schéma l'apparence d'un flocon de neige[3].

- **Avantages du schéma en flocon de neige :**
 - Adapté aux modèles complexes : Permet une modélisation précise grâce à la normalisation des données ;
 - Optimisation du stockage : La normalisation réduit la redondance des données, ce qui permet une meilleure gestion de l'espace ;
 - Amélioration de l'intégrité des données : La structure relationnelle permet un contrôle accru de la cohérence des informations.
- **Inconvénients du schéma en flocon de neige :**
 - Complexité accrue : Sa structure est plus difficile à comprendre et à mettre en œuvre ;
 - Performance des requêtes réduite : Les nombreuses jointures nécessaires peuvent ralentir les performances ;
 - Maintenance plus lourde : L'augmentation du nombre de tables entraîne un suivi plus complexe.




FIGURE 3.3 : Illustration du schéma en flocon de neige [3]

3.6.2.3 Schéma en constellation de faits

Le schéma en constellation de faits est une évolution avancée du schéma en étoile. Dans cette architecture, plusieurs tables de faits partagent un ensemble commun de tables de dimensions comme illustré dans la figure 3.4). Ce modèle est particulièrement utile lorsqu'il existe plusieurs processus métiers à analyser, chacun étant représenté par sa propre table de faits. Les dimensions partagées permettent de croiser les analyses tout en évitant la duplication excessive des données descriptives [14].

- **Avantages du schéma en constellation :**
 - Adapté aux environnements complexes : Gère plusieurs processus métiers simultanément ;
 - Flexibilité élevée : Permet de concevoir des rapports complexes et croisés ;
 - Optimisation analytique : Idéal pour les besoins en BI avancée.
- **Inconvénients du schéma en constellation :**
 - Grande complexité : Plus difficile à comprendre et à maintenir ;




FIGURE 3.4 : Illustration du schéma en constellation de faits [15]

- Performances potentiellement réduites : Les requêtes sur plusieurs tables de faits peuvent être plus lentes ;
- Coût de maintenance élevé : Demande plus de ressources pour la gestion continue.

3.6.2.4 Schéma adopté

Après avoir analysé et comparé les différents types de schémas multidimensionnels, le choix s'est porté sur le schéma en étoile pour la mise en place de notre projet décisionnel. Cette décision repose sur la structure de nos données, organisées autour d'une table de faits centrale reliée à plusieurs dimensions dénormalisées. Le schéma en étoile permet d'optimiser les performances des requêtes, notamment pour les opérations d'agrégation et d'analyse fréquentes. Sa simplicité de conception et de lecture facilite également l'appropriation du modèle par les utilisateurs métier, rendant ainsi cette solution parfaitement adaptée à nos besoins en BI.

3.7 Data Mart

Le tableau suivant présente une description détaillée des tables de dimensions et de faits utilisées dans notre data mart, en précisant leurs attributs ainsi que leur rôle fonctionnel (voir tableau 3.8).

TABLEAU 3.8 : Description des tables de faits et de dimensions du data mart

Nom de la table	Attributs principaux	Description
Fait_contrat	id_temps id_région id_agence id_client id_contrat chiffre_affaires	Table de faits centrale contenant les données contractuelles. Elle est liée aux dimensions client, agence, région et temps. Elle regroupe les mesures quantitatives telles que le chiffre d'affaires, le nombre de clients et d'agences. Cette table constitue le socle des analyses décisionnelles.
dim_client	id_client catégorie_client	Table de dimension décrivant les caractéristiques des clients. Elle permet d'analyser les contrats selon le profil des assurés.
dim_agence	id_agence agence	Table de dimension contenant les informations sur les agences BIAT. Elle permet une analyse géographique et organisationnelle des contrats.
dim_région	id_région région	Table de dimension géographique associée aux agences. Elle facilite les analyses régionales des performances.
dim_temps	id_temps Année Mois	Table de dimension temporelle permettant l'analyse des données selon différentes granularités temporelles (mensuelle, annuelle, etc.).

3.8 Modèles de conception des tableaux de bord

Dans cette section, nous présentons les modèles de conception utilisés pour les tableaux de bord essentiels à la gestion des performances au sein de l'assurance BIAT. Nous décrirons notamment les tableaux de bord suivants :

- Analyse des clients ;
- Analyse des contrats ;
- Analyse des agences.

Chaque tableau de bord a été conçu avec l'objectif de fournir une visualisation claire des

KPIs et de faciliter la prise de décision grâce à des analyses interactives et personnalisables.

3.8.1 Modèle de l'entrepôt de données

Notre entrepôt de données est basé sur le schéma en étoile, conformément à l'approche Kimball. Ce modèle repose sur une table de faits centrale (liée aux contrats) entourée de plusieurs tables de dimensions qui décrivent les axes d'analyse comme le temps, le client, l'agence. La simplicité du schéma en étoile permet une navigation intuitive et des performances optimales pour les requêtes analytiques. Il facilite également la génération de tableaux de bord dynamiques dans Power BI, en réduisant le nombre de jointures nécessaires, comme illustré dans la figure 3.5.




FIGURE 3.5 : Modèle de l'entrepôt de données basé sur le schéma en étoile

3.8.2 Prototypage des dashboards métiers

3.8.2.1 Modèle de dashboard pour l'analyse client

Le dashboard "Analyse des clients" fournit une vue claire et détaillée des principaux indicateurs liés à la gestion de la clientèle. Il met en avant des KPIs tels que l'évolution du chiffre d'affaires, le nombre total de clients, le taux de churn (résiliation) et le taux de fidélité. Ce dashboard permet également d'identifier les meilleurs clients par chiffre d'affaires ainsi que la répartition des clients selon leur type. Grâce à des visualisations telles que des courbes d'évolution, des diagrammes circulaires et des treemaps, l'utilisateur peut facilement détecter les tendances, mesurer la fidélité des clients et analyser les pertes de chiffre d'affaires liées aux départs. Les filtres disponibles par période, type de contrat, région et agence facilitent l'exploration des données comme illustré dans la figure 3.6.




FIGURE 3.6 : Dashboard "Analyse des clients"

3.8.2.2 Modèle de dashboard pour l'analyse des contrats

Le dashboard "Analyse des contrats" permet de suivre et d'évaluer la performance des contrats établis avec les clients. Il présente des KPIs clés tels que le nombre total de contrats, le taux de résiliation, le taux de renouvellement, ainsi que le chiffre d'affaires généré par type de contrat. Les représentations visuelles incluent des histogrammes pour visualiser l'évolution des contrats dans le temps, des diagrammes circulaires pour illustrer la répartition des types de contrats, ainsi que des indicateurs numériques pour faciliter l'analyse rapide. Grâce aux filtres intégrés (par période, client, agence ou région), l'utilisateur peut explorer les données en fonction de critères précis, comme illustré dans la figure 3.7.




FIGURE 3.7 : Dashboard "Analyse des contrats"

3.8.2.3 Modèle de dashboard pour l'analyse des agences

Le dashboard "Analyse des agences" propose une visualisation des performances commerciales par point de vente ou par région. Il regroupe des indicateurs tels que le nombre d'agences, le chiffre d'affaires global, et met en lumière les agences les plus performantes. Une carte géographique interactive permet de localiser les agences et d'effectuer une analyse régionale de la répartition du chiffre d'affaires, tandis que des graphiques en barres et des diagrammes circulaires illustrent la répartition du chiffre d'affaires par agence et par zone géographique. Des filtres permettent d'affiner l'analyse selon la période, le type de contrat ou la région. Ce dashboard permet d'orienter les décisions stratégiques grâce à une lecture simple et visuelle, comme présenté dans la figure 3.8.




FIGURE 3.8 : Dashboard "Analyse des agences"

3.9 Conclusion

La phase de conception est une étape clé dans le développement des tableaux de bord pour le projet d'assurance automobile. En définissant les objectifs, en choisissant des indicateurs pertinents et en structurant une interface adaptée, nous avons pu transformer les données en informations utiles. Ce travail permet à l'assurance BIAT de suivre ses performances, d'identifier les tendances et de faciliter la prise de décision stratégique.

Chapitre 4

Implémentation et audit

4.1 Introduction

Pendant la phase d'implémentation de la méthode GIMSI, l'accent est porté sur les aspects techniques liés à la conception et au déploiement du système de tableaux de bord. Cette étape comprend le choix des outils les plus adaptés, leur intégration dans l'infrastructure existante, ainsi que la mise en place d'un processus de déploiement fluide, sécurisé et performant. L'objectif est d'assurer une transition optimale entre la phase de conception et l'utilisation effective des tableaux de bord par les utilisateurs finaux.

4.2 Processus ETL

Le processus ETL est une étape clé dans l'intégration des données issues de différentes sources, afin de les unifier dans un format cohérent pour l'analyse, le reporting ou d'autres usages. Voici les principales étapes du processus [16] :

- **Extraction** : Les données sont collectées à partir de diverses sources, telles que des bases de données, des fichiers ou des API, afin de rassembler les informations nécessaires ;
- **Transformation** : Les données extraites sont nettoyées, vérifiées et transformées pour correspondre au format attendu par le système cible. Cette étape peut inclure la suppression des doublons, le traitement des valeurs manquantes, ou encore l'application de filtres, d'agrégations ou de tris ;
- **Chargement** : Les données transformées sont ensuite chargées dans le système cible, qu'il s'agisse d'une base de données, d'un entrepôt de données ou d'un outil de visualisation. Elles y sont structurées pour permettre des analyses rapides et efficaces.

Ce processus garantit l'exactitude, la cohérence et l'accessibilité des données pour appuyer la prise de décision. Il peut être automatisé à l'aide d'outils spécialisés afin d'accélérer son exécution et de limiter les erreurs.

4.3 Outils ETL choisis

Pour la mise en œuvre du processus ETL, nous avons opté pour une combinaison d'outils simples, performants et complémentaires. Nous avons utilisé spyder pour la phase de

transformation des données, et Power BI pour le chargement, la visualisation et certaines transformations. Cette approche a permis d'assurer un traitement automatisé, flexible et efficace des données, tout en garantissant une restitution visuelle claire et interactive à travers des tableaux de bord décisionnels.

4.3.1 Langage de programmation : Python

Python est un langage open-source reconnu pour sa puissance dans le traitement de données. Grâce à des bibliothèques telles que `pandas`, et `openpyxl`, il permet de lire les fichiers Excel et CSV, de nettoyer les données, de créer de nouvelles variables, de formater les dates et d'unifier l'ensemble des fichiers historiques (voir figure 4.1). Python a servi de colonne vertébrale à notre transformation des données, avec un script complet facilitant la consolidation de toutes les années d'analyse [17].



FIGURE 4.1 : Logo Python [17]

4.3.2 Environnement de développement : Spyder

Spyder est un environnement de développement intégré (IDE) pour Python, spécialement conçu pour les scientifiques (voir figure 4.2), les ingénieurs et les analystes de données. Il offre une interface conviviale avec des fonctionnalités telles que l'édition de code, le débogage, l'exécution interactive et la visualisation de données [18]. Spyder est souvent utilisé avec des bibliothèques scientifiques comme NumPy, SciPy, Matplotlib et Pandas, ce qui en fait un outil puissant pour l'analyse de données et le calcul scientifique.



FIGURE 4.2 : Logo Spyder [18]

4.3.3 Bibliothèques Python utilisées

Plusieurs bibliothèques spécialisées ont été utilisées, chacune jouant un rôle précis dans le pipeline ETL :

- Extraction : **Pandas** (voir figure 4.3) pour la lecture de fichiers Excel et CSV, avec **openpyxl** (voir figure 4.4) comme moteur dédié à l'importation des fichiers **.xlsx** ;
- Transformation : **Pandas** a été utilisé pour le nettoyage, la sélection de colonnes, le renommage, le typage, et la fusion des données. **Numpy** (voir figure 4.5) a été utilisé pour des opérations numériques, comme le calcul des pertes avec `np.abs()` ;
- Chargement : **Pandas** a également été utilisé pour sauvegarder les données consolidées aux formats **Excel** et **CSV** avec un encodage adapté à l'exportation.

Ces bibliothèques ont permis de construire un pipeline automatisé et fiable pour regrouper, nettoyer et structurer les données issues de plusieurs années d'assurance automobile.



FIGURE 4.3 : Logo Pandas [19]




FIGURE 4.4 : Logo Openpyxl [20]



FIGURE 4.5 : Logo Numpy [21]

4.3.4 Sources de données

Toutes les données du projet proviennent de fichiers Excel annuels (2020 à 2024) fournis par l'entreprise. Chaque fichier contient des informations sur les contrats, les clients et les agences. Ils ont été lus avec la bibliothèque `pandas` en utilisant le moteur `openpyxl`, puis normalisés pour assurer une structure homogène. Cette étape a permis de consolider l'ensemble des données en une seule base prête pour le traitement ETL.

4.3.5 Destination des données

Les données transformées ont été exportées au format **CSV** avec un encodage **UTF-8-SIG**, afin d'assurer une compatibilité optimale avec Power BI. Ce fichier regroupe toutes les données consolidées sur plusieurs années et comprend les colonnes nettoyées et enrichies (chiffre d'affaires, statut, type de contrat, région, etc.). Ce format léger et structuré permet une intégration directe dans Power BI pour la création de rapports interactifs.

4.3.6 Outil de visualisation : Power BI

Power BI, développé par Microsoft, est utilisé comme un outil de BI pour construire des tableaux de bord à partir des données transformées. Il offre des fonctionnalités avancées de visualisation interactive, tout en restant accessible aux utilisateurs non techniques grâce à une interface intuitive (voir figure 4.6). Dans notre projet, Power BI a permis une exploration visuelle intuitive des résultats issus du traitement ETL réalisé en amont. Il a également été utilisé pour effectuer certaines transformations supplémentaires via Power Query, telles que la normalisation de colonnes, le filtrage de valeurs ou la création de dimensions d'analyse. Son intégration fluide avec les fichiers CSV produits par Python a facilité la construction de rapports dynamiques et fiables, accessibles en ligne et partageables entre utilisateurs [22].



FIGURE 4.6 : Logo Power BI [22]

4.4 Extraction des données

L'extraction des données constitue la première étape essentielle du projet décisionnel. Elle vise à rassembler les informations brutes nécessaires à l'analyse des contrats d'assurance automobile. Dans notre cas, les données ont été extraites depuis des fichiers Excel au format `.xlsx`, représentant les années de 2020 à 2024 (voir figure 4.7). Chaque fichier contient des données clés telles que les identifiants de contrat, le mois d'exercice, les types de contrat, les codes client et agences, les montants de chiffre d'affaires, ainsi que des informations sur la catégorie du client. Comme illustré dans la figure 4.8, l'extraction a été

EXERCICE	TMP_MONTH	TMP_TYPE_CDE	TMP_POL_EXT_CDE	TMP_AGENT_CDE	TMP_MVT	TMP_START_DATE	TMP_END_DATE	TMP_RUN_DATE
2020	202001	A	0101050005912	100	12	07/11/2019	06/11/2020	06/02/2020
2020	202001	T	0101180000054	701	572	05/01/2020	04/01/2021	21/12/2019
2020	202001	T	0101190000176	100	572	18/01/2020	17/01/2021	21/12/2019
2020	202001	T	0101050003138	700	12	01/01/2020	31/12/2020	21/12/2019
2020	202001	T	0101160000559	712	572	23/01/2020	22/01/2021	21/12/2019
2020	202001	C	0101200000192	105005	572	15/01/2020	14/01/2021	06/02/2020
2020	202001	T	0101100001203	700	12	28/01/2020	27/01/2021	21/12/2019
2020	202001	T	0101080000802	100	12	29/01/2020	28/01/2021	21/12/2019
2020	202001	A	0101120000202	100	12	11/08/2017	10/08/2018	06/02/2020
2020	202001	T	0101060001118	700	12	30/01/2020	29/01/2021	21/12/2019
2020	202001	T	0101160000669	712	572	30/01/2020	29/01/2021	21/12/2019
2020	202001	T	0101100001529	712	12	18/01/2020	17/01/2021	21/12/2019
2020	202001	C	0101160005575	706	612	03/12/2019	01/12/2020	06/02/2020
2020	202001	T	0101120000015	100	12	25/01/2020	24/01/2021	21/12/2019
2020	202001	T	0101170000198	706	12	18/01/2020	17/01/2021	21/12/2019
2020	202001	C	0101200000218	712	12	16/01/2020	15/01/2021	06/02/2020
2020	202001	T	0101100000927	288	12	16/01/2020	15/01/2021	21/12/2019
2020	202001	T	0101190000174	700	572	21/01/2020	20/01/2021	21/12/2019
2020	202001	T	0101150000013	150	572	03/01/2020	02/01/2021	21/12/2019

FIGURE 4.7 : Extrait de la base de données Excel utilisée pour l'analyse

```

import pandas as pd
import numpy as np

paths = {
    "2020": r"C:\PFE\excel\base auto 2020_projet stage.xlsx",
    "2021": r"C:\PFE\excel\base auto 2021_projet stage.xlsx",
    "2022": r"C:\PFE\excel\base auto 2022_projet stageeee.xlsx",
    "2023": r"C:\PFE\excel\base auto 2023_projet stage.xlsx",
    "2024": r"C:\PFE\excel\base auto 2024_projet stage.xlsx"
}

colonnes_utiles = [
    "EXERCICE", "TMP_MONTH", "TMP_TYPE_CDE", "TMP_POL_EXT_CDE",
    "TMP_AGENT_CDE", "TMP_CLIENT_CDE", "CA", "CONTRAT_TYPE", "CATEGORIE_CLIENT"
]

```

FIGURE 4.8 : Exemple de script Python pour l'extraction des fichiers Excel

réalisée à l'aide du langage Python, en s'appuyant sur les bibliothèques `pandas` et `numpy`. Le dictionnaire `paths` a été utilisé pour définir les chemins d'accès aux différents fichiers. Ensuite, seuls les champs pertinents ont été sélectionnés via la variable `colonnes_utiles`, ce qui a permis de filtrer les données dès l'importation. Grâce à cette méthode automatisée, chaque fichier a pu être chargé dans un `DataFrame`, garantissant une lecture fiable, une gestion souple des chemins et une première étape de structuration des données. Cette extraction maîtrisée constitue ainsi la base sur laquelle repose toute la suite du traitement ETL et la visualisation dans Power BI.

4.5 Transformation des données

La phase de transformation constitue une étape cruciale dans notre projet décisionnel. Elle permet de structurer et préparer les données extraites afin de les rendre exploitables pour l'analyse. Cette étape comprend plusieurs opérations clés : Fusion de fichiers, nettoyage des colonnes, traitement des doublons et des valeurs manquantes, normalisation des dates, et renommage des champs pour les adapter aux objectifs du projet. Ces transformations garantissent la qualité, la lisibilité et la pertinence des données analysées dans Power BI.

4.5.1 Transformation des données avec Python

La première phase de transformation a été réalisée en utilisant le langage Python, notamment à l'aide des bibliothèques `pandas` et `numpy`. Celles-ci ont permis d'automatiser le traitement des données brutes, de les structurer, et de générer une base consolidée exploitable dans Power BI.

Les principales étapes du processus sont les suivantes :

- Les fichiers Excel des années 2020 à 2024 ont été lus individuellement à l'aide de `pandas.read_excel()`, en sélectionnant uniquement les colonnes utiles dès l'importation ;
- Chaque fichier a été nettoyé : Typage des colonnes, suppression des valeurs inutiles, conversion des montants et standardisation des catégories clients et types de contrat ;
- Une colonne supplémentaire `SOURCE_ANNEE` a été ajoutée pour identifier la provenance temporelle de chaque ligne ;
- Les fichiers ont ensuite été fusionnés dans un seul DataFrame à l'aide de `pd.concat()` ;
- Une gestion des valeurs manquantes a été effectuée ;
- Les noms d'agences ont été déduits à partir des codes grâce au dictionnaire `mapping_agents`, et les régions associées via `mapping_regions` ;
- Le chiffre d'affaires a été divisé en deux colonnes : `Perte` (pour les types A et R) et `CA_Gain` (pour les types C et T), selon une fonction dédiée ;
- Une colonne `Statut` a été générée à partir de chiffres spécifiques du code police, différenciant les contrats `Individuel`, `Flotte` ou `Autre`, selon l'année ;
- Le mois a été normalisé en extrayant les deux derniers chiffres de `TMP_MONTH`, assurant une cohérence temporelle sur toutes les années ;
- Enfin, le DataFrame final a été exporté au format `CSV` (avec encodage `UTF-8-SIG`) et `Excel`, prêt pour la visualisation dans Power BI.

Les différentes figures suivantes illustrent les étapes clés de ce processus :

- La figure 4.9 montre le chargement des fichiers Excel et leur nettoyage initial ;

```
df_liste = []
for annee, chemin in paths.items():
    try:
        df = pd.read_excel(chemin, usecols=lambda x: x in colonnes_utiles, engine="openpyxl")
        df.columns = df.columns.str.strip()
        df["TMP_POL_EXT_CDE"] = df["TMP_POL_EXT_CDE"].astype(str)
        df["TMP_CLIENT_CDE"] = df["TMP_CLIENT_CDE"].apply(lambda x: str(int(float(x))) if pd.notnull(x) and x != "" else "0")
        df["CA"] = pd.to_numeric(df["CA"], errors="coerce").fillna(0)
        df["CONTRAT_TYPE"] = df["CONTRAT_TYPE"].str.upper().replace({"NC": "Nouveau contrat", "AC": "Ancien contrat"})
        df["CATEGORIE_CLIENT"] = df["CATEGORIE_CLIENT"].replace({"PP": "Personne physique", "PM": "Personne morale"})
        df["SOURCE_ANNEE"] = annee
        df_liste.append(df)
        print(f"Fichier {annee} chargé.")
    except Exception as e:
        print(f"Erreur chargement {annee} : {e}")
df_final = pd.concat(df_liste, ignore_index=True)
```

FIGURE 4.9 : Chargement et nettoyage des fichiers Excel

```
mapping_agents = {
    107: "Biat", 700: "Agence Tunis", 701: "Agence Ariana", 702: "Agence Lac1",
    703: "Agence Megrine", 704: "Agence Manouba", 705: "Agence Bizerte",
    706: "Agence Nabeul", 708: "Agence Sousse Centre", 710: "Agence Gabes",
    711: "Agence Sfax Sekit Ezzit", 712: "Agence Sfax Chaker", 713: "Agence Djerba Midoun",
    714: "Agence Gabes", 100: "Bureau Direct"
}
mapping_regions = {
    "Agence Tunis": "Tunis", "Agence Ariana": "Ariana", "Agence Megrine": "Ben Arous",
    "Agence Lac1": "Tunis", "Agence Manouba": "Manouba", "Agence Bizerte": "Bizerte",
    "Agence Nabeul": "Nabeul", "Agence Sousse Centre": "Sousse", "Agence Sfax Sekit Ezzit": "Sfax",
    "Agence Gabes": "Gabes", "Agence Djerba Midoun": "Medenine", "Bureau Direct": "Tunis",
    "Agence Sfax Chaker": "Sfax"
}
```

FIGURE 4.10 : Création de dictionnaires de mappage pour les agents et les régions

```
def calculer_ca(row):
    if row.get("TMP_TYPE_CDE") in ["A", "R"]:
        return abs(row["CA"]), 0
    elif row.get("TMP_TYPE_CDE") in ["C", "T"]:
        return 0, row["CA"]
    return 0, 0

df_final[["Perte", "CA_Gain"]] = df_final.apply(calculer_ca, axis=1, result_type="expand")
```

FIGURE 4.11 : Création des colonnes

```
def extraire_statut(row):
    code = str(row["TMP_POL_EXT_CDE"]).zfill(10)

    if row["EXERCICE"] == 2021:
        digits = code[2:4]
    else:
        digits = code[1:3]

    if digits == "01":
        return "Individuel"
    elif digits == "02":
        return "Flotte"
    else:
        return "Autre"

df_final["Statut"] = df_final.apply(extraire_statut, axis=1)

df_final["TMP_MONTH"] = df_final["TMP_MONTH"].astype(str).str[-2:].astype(int)
```

FIGURE 4.12 : Création de la colonne Statut et normalisation du mois

- La figure 4.10 présente les dictionnaires utilisés pour enrichir les données avec les noms d'agences et les régions;
- La figure 4.11 illustre la fonction qui permet de calculer les colonnes **Perte** et **CA_Gain**;
- La figure 4.12 décrit la génération de la colonne **Statut** et la normalisation du mois;

```
file_base_final_csv = r"C:\PFE\excel\base_auto_toutes_annees.csv"
df_final.to_excel(file_base_final_xlsx, index=False)
df_final.to_csv(file_base_final_csv, index=False, encoding="utf-8-sig", sep=";")
```

FIGURE 4.13 : Script d'export final de la base consolidée

- La figure 4.13 montre l'export final du fichier nettoyé au format Excel et CSV.

4.5.2 Transformation complémentaire avec Power BI

Une fois la base de données consolidée avec Python, des ajustements supplémentaires ont été effectués dans Power BI à l'aide de l'éditeur Power Query, dans le but d'améliorer la qualité des données et leur lisibilité dans les rapports.

Comme illustré dans la figure 4.14, plusieurs étapes successives ont été appliquées :

- Les types de données ont été modifiés (texte, entier, date) pour garantir la cohérence des formats et éviter les erreurs de lecture ;
- Des colonnes personnalisées ont été ajoutées pour effectuer des calculs intermédiaires ou enrichir les données avec des règles métiers ;
- Plusieurs colonnes ont été renommées pour améliorer la lisibilité et l'interprétation dans les visuels ;
- Une mise en majuscule automatique a été appliquée pour uniformiser la présentation des libellés ;
- Enfin, des colonnes non pertinentes ont été supprimées et d'autres permutées pour alléger le modèle et se concentrer sur les variables essentielles.

Ces opérations ciblées, bien que légères, ont permis d'optimiser la structure finale des données pour une exploitation efficace à travers des tableaux de bord interactifs et intuitifs.




FIGURE 4.14 : Étapes de transformation effectuées dans Power Query

4.6 Chargement des données

Après les phases d'extraction et de transformation des données, l'étape finale du processus ETL consiste à charger les données préparées dans l'outil de visualisation. Dans notre cas, la base consolidée a été importée dans Power BI pour permettre l'analyse interactive à travers des tableaux de bord dynamiques. Les données ont été exportées depuis Python sous format `.csv` puis chargées dans Power BI via l'éditeur Power Query. Cette opération a permis de structurer le modèle de données en tables de faits et de dimensions (clients, agences, temps et régions).

- Chargement du fichier consolidé contenant toutes les années (2020–2024). Ce fichier centralise les données nettoyées issues de Python et sert de source principale pour les analyses.
- Création de requêtes séparées pour les dimensions (clients, temps, agences, régions) à partir du fichier principal. Cela permet une meilleure modélisation et une organisation claire des axes d'analyse.
- Définition des relations entre les tables afin d'obtenir un modèle en étoile adapté aux analyses. Cette structure relationnelle favorise l'efficacité des mesures DAX et la navigation dans les rapports.
- Vérification des types de données et optimisation pour améliorer les performances d'affichage. Des ajustements ont été faits pour éviter les erreurs de format et accélérer le temps de chargement des visuels.
- Création de mesures et de KPIs pour suivre les performances (Chiffre d'affaires, pertes, fidélité, churn, etc.). Ces KPIs sont essentiels pour guider la prise de décision et évaluer les objectifs de l'entreprise.

4.7 Création des tableaux de bord

Dans cette section, nous présentons une vue d'ensemble des différents tableaux de bord développés dans le cadre du projet. Ces tableaux de bord ont été conçus dans Power BI dont le but de fournir des indicateurs visuels pertinents sur plusieurs dimensions de l'activité de l'assurance automobile. Chaque tableau de bord répond à un objectif spécifique et permet de faciliter la prise de décision grâce à une visualisation claire et interactive des données. Les analyses proposées couvrent plusieurs volets :

- Volet Analyse des clients : Permet de suivre l'évolution de la clientèle et ses comportements ;
- Volet Analyse des contrats : Donne une vue globale sur la gestion et la dynamique des contrats ;
- Volet Analyse des agences : Met en évidence la performance commerciale des différentes agences.

4.7.1 Tableau de bord analyse des clients

La figure 4.15 offre une vue d'ensemble complète sur le comportement et la structure de la clientèle. Ce tableau de bord permet aux parties prenantes d'analyser les tendances d'acquisition, de fidélisation et de contribution des clients au chiffre d'affaires global. Les différents visuels composant ce tableau de bord sont analysés dans le tableau 4.9, qui décrit le rôle et les données clés de chaque élément. Ce tableau de bord peut également




FIGURE 4.15 : Tableau de bord "Analyse des clients"

être filtré selon la période, le type de contrat, la région, l'agence ou encore un client spécifique, pour affiner l'analyse.

TABLEAU 4.9 : Description des visuels du tableau de bord "Analyse des clients"

Type de visuel	Description du visuel	Interprétation
Tuiles KPI (Nombre total de clients, taux de churn, taux de fidélité)	Trois tuiles synthétiques affichent les indicateurs clés : Le nombre de clients actifs, le taux de départs et le taux de fidélisation. Elles permettent une lecture rapide de la stabilité commerciale.	Le portefeuille client de l'assurance BIAT présente un bon équilibre, avec un taux de churn relativement faible (11,16 %) et un taux de fidélité élevé (68,56 %), traduisant une forte capacité à conserver les clients.
Histogramme horizontal (Top 5 des clients par chiffre d'affaires)	Graphique horizontal classant les clients selon leur part dans le chiffre d'affaires. Il aide à repérer les clients les plus importants.	Les cinq premiers clients contribuent largement au chiffre d'affaires total. Leur poids stratégique nécessite un suivi renforcé pour maintenir cette rentabilité.

Suite du tableau 4.9

Courbe (Évolution du chiffre d'affaires)	Une courbe chronologique qui retrace l'évolution mensuelle du chiffre d'affaires de 2020 à 2024, utile pour anticiper les cycles d'activité.	On observe une saisonnalité marquée avec des pics de vente réguliers en fin d'année. Le chiffre d'affaires mensuel oscille entre 5 et 10 millions TND.
Camembert (Répartition des clients par type)	Diagramme circulaire illustrant la répartition des clients entre entreprises et particuliers. Il aide à adapter les offres selon le profil de clientèle.	La majorité des clients sont des personnes morales (85,16 %), ce qui reflète une clientèle principalement composée d'entreprises. Les particuliers ne représentent que 14,84 %.
Anneau (Analyse du chiffre d'affaires)	Diagramme en anneau comparant la part du chiffre d'affaires conservée par la société et la part perdue.	Le chiffre d'affaires global atteint 173,93 millions TND. Parmi ce total, seules 8,88 millions TND (4,86 %) ont été perdues à cause de résiliations, traduisant un bon niveau de rétention.
Double courbe (Évolution du nombre de clients)	Deux courbes superposées illustrant l'évolution annuelle du nombre de nouveaux clients par rapport aux clients récurrents.	La courbe des nouveaux clients connaît une évolution irrégulière, avec une hausse jusqu'en 2021, une baisse en 2022 probablement liée à l'impact du Covid, puis une reprise en 2023. En parallèle, la courbe des anciens clients progresse de manière continue, ce qui traduit une bonne fidélisation au fil des années.

4.7.2 Tableau de bord analyse des contrats

La figure 4.16 offre une vue d'ensemble complète de la gestion des contrats d'assurance automobile, permettant aux parties prenantes d'analyser les indicateurs clés de performance, de fidélisation et de résiliation. Les différents visuels composant ce tableau de bord sont analysés dans le tableau 4.10, qui décrit le rôle et l'utilité de chaque élément. Ce tableau de bord peut également être filtré dynamiquement selon la période, le type de contrat, la catégorie de client, la région ou un code client spécifique pour une analyse ciblée.




FIGURE 4.16 : Tableau de bord "Analyse des contrats"

TABLEAU 4.10 : Description des visuels du tableau de bord "Analyse des contrats"

Type de visuel	Description du visuel	Interprétation
Carte d'indicateurs (Tuiles KPI : Indicateur de renouvellement, nombre total de contrats, taux de churn)	Trois indicateurs affichés en haut du dashboard permettant de visualiser les performances globales du portefeuille de contrats.	Sur 67 000 contrats, 72,82 % ont été renouvelés, dépassant largement l'objectif de 50 %. Le taux de churn est faible (2,76 %), ce qui montre une forte rétention contractuelle.
Histogramme vertical (Évolution du nombre de contrats 2020–2024)	Histogramme empilé représentant la répartition annuelle des nouveaux contrats, contrats résiliés et contrats totaux.	Le volume total reste stable à environ 20 000 contrats par an. Entre 3 000 et 4 000 sont des nouveaux contrats, tandis que les contrats résiliés ne dépassent pas les 2 000.
Histogramme horizontal (Répartition du chiffre d'affaires par type de contrat)	Barres horizontales comparant le chiffre d'affaires selon le type de contrat et l'année. Permet de mesurer la rentabilité par ancienneté.	Les anciens contrats génèrent la majorité du chiffre d'affaires, surtout en 2024. Les nouveaux contrats participent aussi, mais de manière plus modérée.

Suite du tableau 4.10

Type de visuel	Description du visuel	Interprétation
Diagramme circulaire (Répartition des contrats par type : Renouvelés vs résiliés)	Camembert illustrant visuellement la part des contrats renouvelés par rapport aux résiliations.	96,59 % des contrats sont renouvelés ($\approx 52\,000$), contre seulement 3,41 % résiliés ($\approx 2\,000$).
Tableau (Informations contractuelles des clients)	Tableau de données brutes montrant les colonnes : numéro de contrat, type, catégorie client et statut.	Ce tableau regroupe toutes les informations contractuelles, avec la possibilité de filtrer par code client afin d'afficher l'ensemble des contrats liés à un client spécifique.

4.7.3 Tableau de bord analyse des agences

La figure 4.17 présente une vue synthétique des performances commerciales selon les différentes agences réparties sur le territoire. L'utilisateur peut sélectionner l'année d'analyse et appliquer des filtres spécifiques tels que le type de contrat, la catégorie de client et la région. Les visuels de ce tableau de bord sont décrits dans le tableau 4.11, qui détaille leur contenu et leur rôle analytique.




FIGURE 4.17 : Tableau de bord "Analyse des agences"

TABLEAU 4.11 : Description des visuels du tableau de bord "Analyse des agences"

Type de visuel	Description du visuel	Interprétation
Carte d'indicateurs (Nombre total d'agences, chiffre d'affaires total)	Deux tuiles résumant le nombre d'agences en activité et leur chiffre d'affaires cumulé sur la période.	Le réseau se compose de 14 agences ayant généré un chiffre d'affaires total de 173,93 millions TND. Cela montre une couverture géographique relativement concentrée mais performante.
Barre horizontale (Top 5 agences les plus performantes)	Visualisation des cinq agences les plus rentables, utile pour prioriser les ressources et récompenser la performance.	L'agence Bureau Direct est celle ayant généré le plus de chiffre d'affaires, suivie par d'autres agences stratégiques. Ce classement aide à repérer les points forts du réseau.
Diagramme circulaire (Répartition du chiffre d'affaires par agence)	Camembert illustrant la part de chaque agence dans le chiffre d'affaires global. Permet d'identifier les déséquilibres ou les zones à potentiel.	L'agence Bureau Direct génère à elle seule près de 64 % du chiffre d'affaires (≈ 111 M TND). Les autres agences restent marginales en comparaison, ce qui révèle une forte concentration de performance.
Carte géographique (Analyse régionale)	Carte interactive localisant les agences par région, où la taille des cercles verts illustre la répartition du chiffre d'affaires de chaque agence selon la catégorie de client. Cet outil permet une lecture claire de la performance géographique.	Le chiffre d'affaires est majoritairement concentré dans les régions du nord (Tunis, Ariana, Bizerte, Nabeul), reflétant une forte activité urbaine. Les cercles verts illustrent la répartition du chiffre d'affaires par catégorie de client.
Tableau (Matrice des indicateurs par agence)	Tableau synthétique listant, pour chaque agence, le nombre total de contrats, de clients et d'indicateurs clés.	Ce tableau regroupe l'ensemble des informations relatives à chaque agence, telles que le numéro d'agence, le nombre total de clients, le nombre total de contrats, le chiffre d'affaires réalisé ainsi que le taux de renouvellement.

4.8 Audit

L'audit constitue la dernière étape de la méthode GIMSI pour la mise en place du système décisionnel dédié au produit automobile au sein d'assurance BIAT. Même si cette phase reste facultative, elle joue un rôle important dans le maintien de la performance et l'adaptabilité du système dans le temps. Son objectif principal est de s'assurer que les solutions mises en œuvre restent alignées avec les objectifs stratégiques de l'entreprise et les attentes évolutives des clients. En effet, les besoins changent, et ce contrôle permet d'identifier les écarts éventuels et d'y remédier de manière proactive. L'audit s'articule généralement autour de quatre axes :

- Repérer les points à améliorer ;
- Réaliser des entretiens et recueillir les retours d'expérience ;
- Étudier les résultats obtenus ;
- Proposer des actions correctives adaptées.

Dans le cas d'assurance BIAT, cette phase n'est pas obligatoire, mais elle reste essentielle pour anticiper les éventuelles anomalies et ajuster le système aux évolutions futures.

4.9 Conclusion

En conclusion, ce chapitre a présenté la mise en œuvre de notre modèle d'entrepôt de données, en mettant en avant les étapes ETL. Grâce à l'utilisation de Python pour le traitement des données et de Power BI pour la création des tableaux de bord, nous avons construit une base solide pour l'intégration et l'analyse des données. Ces technologies nous ont permis de centraliser les informations de manière cohérente et d'offrir des visualisations claires et interactives. Ainsi, ce système fournit à l'assurance BIAT des indicateurs fiables, facilitant la prise de décision stratégique et la mise en place d'actions ciblées.

Chapitre 5

Analyse avancée des données des clients de l'assurance BIAT : Prévision, segmentation et prédiction

5.1 Introduction

Dans ce chapitre, nous présentons une approche analytique avancée visant à appuyer la prise de décision stratégique au sein de l'assurance BIAT. Celle-ci repose sur trois axes principaux : La prévision des KPIs, la segmentation des clients selon leur fidélité et leur comportement historique, ainsi que la prédiction du comportement futur des clients. Ces analyses permettent d'anticiper les risques, de détecter les clients à forte valeur, et de proposer des actions ciblées pour améliorer la performance commerciale et la fidélisation.

5.2 Prévision du chiffre d'affaires et du nombre de clients

La prévision d'une série temporelle est une approche statistique permettant d'estimer les valeurs futures d'une variable chronologique en se basant sur ses données historiques. Dans le cas de l'assurance BIAT, cette méthode est utilisée pour anticiper l'évolution du chiffre d'affaires total ainsi que du nombre global de clients. L'objectif principal est d'apporter une vision claire sur la dynamique commerciale de l'entreprise afin d'aider les décideurs à adapter leurs stratégies de fidélisation, d'optimisation des ressources et de développement de portefeuille client. Une prévision fiable de ces KPIs constitue un levier essentiel pour améliorer la performance globale et orienter les actions futures.

5.2.1 Notions de base des séries temporelles

- La tendance (T_t) : Elle représente la direction générale de la série (croissante ou décroissante) sur une période prolongée.
- La saisonnalité (S_t) : Elle traduit les fluctuations périodiques et régulières observées au cours du temps.
- Le résidu (E_t) : Il regroupe les variations aléatoires qui ne sont expliquées ni par la tendance, ni par la saisonnalité.

Avant toute modélisation, il est essentiel de vérifier si la série est *stationnaire*, c'est-à-dire si ses caractéristiques statistiques (moyenne, variance) restent constantes dans le temps. Une série stationnaire est généralement requise pour garantir la fiabilité des méthodes de prévision. Dans ce travail, deux approches ont été utilisées pour analyser la stationnarité [23] :

- La méthode graphique : À travers la visualisation des courbes temporelles et l'application d'un lissage par moyenne mobile centrée, il a été possible de détecter la présence d'une tendance ou d'une variation saisonnière.
- Le test statistique : Le test de Dickey-Fuller augmenté (ADF) a été appliqué pour valider formellement la stationnarité ou non de la série en calculant la p-value associée.

Ces étapes préparatoires permettant d'ajuster les données de manière appropriée avant de procéder aux prévisions, assurant ainsi la qualité des résultats obtenus.

5.2.2 Analyse exploratoire des données

L'analyse exploratoire constitue une phase essentielle pour structurer les données et garantir leur fiabilité avant toute modélisation. Dans cette étude, les données issues des contrats d'assurance ont été exploitées pour générer deux séries temporelles mensuelles : Le chiffre d'affaires et le nombre total de clients uniques par mois. La figure 5.1 présente les scripts Python utilisés pour effectuer les principales opérations de préparation, notamment le nettoyage des colonnes, la transformation des dates, l'agrégation mensuelle des données, ainsi que l'application d'un lissage afin de réduire les variations ponctuelles. Cette préparation a permis d'uniformiser les données, de faciliter la lecture des tendances et d'assurer une base solide pour les analyses prévisionnelles à venir. Les séries obtenues sont désormais prêtes à être testées dans les modèles de prévision.

```
df = pd.read_csv("C:/PFE/excel/base_auto_toutes_annees.csv", delimiter=';', encoding='utf-8-sig', low_memory=False)
df.columns = df.columns.str.strip()
df['Date'] = pd.to_datetime(df['EXERCICE'].astype(str) + '-' + df['TMP_MONTH'].astype(str) + '-01', errors='coerce')
df = df.dropna(subset=['Date', 'CA'])
df['CA'] = pd.to_numeric(df['CA'], errors='coerce')
df = df.dropna(subset=['CA'])
df = df.groupby(pd.Grouper(key='Date', freq='M')).agg({'CA': 'mean'})
df = df[df.index.notna()]
df['CA'] = df['CA'].rolling(window=3, center=True).mean()
df = df.dropna(subset=['CA'])

df = df.dropna(subset=['Date', 'TMP_CLIENT_CDE'])
df['TMP_CLIENT_CDE'] = df['TMP_CLIENT_CDE'].astype(str)
df_clients = df.groupby(['Date'])['TMP_CLIENT_CDE'].nunique().reset_index()
df_clients = df_clients.rename(columns={'TMP_CLIENT_CDE': 'Nombre_Clients'})
df_clients = df_clients.set_index('Date')
df_clients = df_clients[df_clients.index.notna()]
```

FIGURE 5.1 : Script de préparation des données

5.2.3 Étude de la stationnarité

Avant d'appliquer les modèles de prévision sur le chiffre d'affaires et le nombre total de clients, une étude de la stationnarité des séries temporelles a été réalisée. Cette étape est essentielle pour garantir la pertinence des modèles statistiques, qui nécessitent généralement des séries stationnaires [24].

5.2.3.1 Vérification de la stationnarité avec le test ADF

La stationnarité d'une série temporelle est une condition fondamentale pour l'application correcte de nombreuses méthodes de prévision. Pour évaluer la stationnarité des séries ana-

lys es, nous avons eu recours au test de Dickey-Fuller augment  (ADF), un test statistique reconnu dans l'analyse des s ries chronologiques. Ce test repose sur deux hypoth ses :

- H_0 : La s rie poss de une racine unitaire, elle est donc non stationnaire ;
- H_1 : La s rie ne poss de pas de racine unitaire, elle est donc stationnaire.

L'interpr tation repose sur la comparaison entre la p-value obtenue et un seuil de signification fix    0,05. Si la p-value est inf rieure   ce seuil, l'hypoth se nulle est rejet e, et la s rie est consid r e comme stationnaire. Dans notre  tude, ce test a  t  appliqu  aux deux indicateurs principaux : Le chiffre d'affaires total agr g  par mois et le nombre total de clients uniques par mois. Le code Python utilis  pour appliquer ce test est pr sent  dans la figure 5.2, tandis que les r sultats obtenus sont illustr s dans la figure 5.3. Ces derniers montrent que les deux s ries sont non stationnaires, ce qui a n cessit  une pr paration suppl mentaire avant l'application des mod les pr visionnels.

```
adf_p = adfuller(df_clients['Nombre_Clients'])[1]
used_log = False
if adf_p > 0.05:
    df_clients['y'] = np.log1p(df_clients['Nombre_Clients'])
    used_log = True
else:
    df_clients['y'] = df_clients['Nombre_Clients']

adf_p = adfuller(df['CA'])[1]
used_log = False
if adf_p > 0.05:
    df['y'] = np.log1p(df['CA'])
    used_log = True
    print(f"P-value ADF = {adf_p:.4f} → La s rie est NON stationnaire (log appliqu ).")
else:
    df['y'] = df['CA']
    print(f"P-value ADF = {adf_p:.4f} → La s rie est stationnaire.")
```

FIGURE 5.2 : Script du test statistique ADF

```
P-value ADF = 0.5088 → La s rie est NON stationnaire
P-value ADF = 0.6189 → La s rie est NON stationnaire
```

FIGURE 5.3 : R sultats du test ADF

5.2.3.2 Stabilisation de la s rie temporelle

Les r sultats du test ADF ont r v l  que les s ries du chiffre d'affaires total et du nombre total de clients  taient non stationnaires (voir figure 5.3). Pour y rem dier, une transformation logarithmique a  t  appliqu e lorsque la p-value d passait 0,05, comme illustr  dans le code Python (voir figure 5.2). Cette transformation permet de stabiliser la variance et de rendre les s ries stationnaires, ce qui est essentiel pour garantir la validit  des mod les de pr vision.

5.2.4 Division des donn es en des ensemble d'entra nement et de test

Avant d'entra ner les mod les de pr vision, les s ries temporelles ont  t  divis es en deux ensembles : Un ensemble d'entra nement repr sentant 70% des donn es, et un ensemble de test repr sentant les 30% restants. Cette s paration permet de faire l'apprentissage des mod les sur les donn es pass es, puis de valider leur performance sur des observations non utilis es durant l'entra nement. La figure 5.4 montre l'instruction Python utilis e pour effectuer cette division   l'aide de la m thode `iloc()`, en se basant sur la taille du DataFrame.

```
train_size = int(len(df) * 0.7)
train = df.iloc[:train_size]
test = df.iloc[train_size:]

train_size = int(len(df_clients) * 0.7)
train = df_clients.iloc[:train_size]
test = df_clients.iloc[train_size:]
```

FIGURE 5.4 : Script de division des donn es temporelles en ensembles d'entra nement et de test

5.2.5 Cr ation des mod les

Dans cette partie, nous avons  valu  plusieurs mod les de pr vision afin d'identifier celui qui s'adapte le mieux aux caract ristiques de nos donn es. Trois approches ont  t  retenues : Holt-Winters, XGBoost et SARIMA,. Chacune de ces m thodes pr sente des avantages sp cifiques pour la mod lisation des s ries temporelles  tudi es, permettant de comparer leurs performances sur le chiffre d'affaires total et le nombre total de clients.

5.2.5.1 Le mod le Holt-Winters

Le mod le de Holt-Winters repose sur un lissage exponentiel triple, con u pour les s ries temporelles combinant   la fois une tendance et une saisonnalit  [25]. Dans le cadre de cette  tude, la version additive a  t  privil gi e afin de mod liser une saisonnalit  mensuelle et une tendance lin aire. Avant d'estimer les valeurs futures, une v rification pr alable est effectu e pour s'assurer que la s rie dispose d'au moins 24 observations, condition n cessaire   une mod lisation fiable. Lorsque ce seuil est atteint, le mod le est ajust  sur les donn es d'apprentissage et une pr vision sur un horizon de 36 mois est g n r e, comme illustr  dans la figure 5.5. L'impl mentation repose sur la fonction `ExponentialSmoothing`, fournie par la biblioth que `statsmodels.tsa.holtwinters`. Les figures 5.6 et 5.7 montrent les pr visions du chiffre d'affaires et du nombre de clients.

```

if len(train) >= 24:
    model_hw = ExponentialSmoothing(train['y'], trend='add', seasonal='add', seasonal_periods=12).fit()
    future_dates_hw = pd.date_range(df.index.max() + pd.DateOffset(months=1), periods=36, freq='M')
    future_hw = pd.Series(model_hw.forecast(36).values, index=future_dates_hw)
else:
    future_hw = pd.Series([np.nan]*36, index=pd.date_range(df.index[-1] + pd.DateOffset(months=1), periods=36, freq='M'))

```

FIGURE 5.5 : Script de l'implémentation du modèle Holt-Winters




FIGURE 5.6 : Illustration des résultats de prévision du chiffre d'affaires à l'aide du modèle Holt-Winters




FIGURE 5.7 : Illustration des résultats de prévision du nombre de clients à l'aide du modèle Holt-Winters

La première met en évidence une tendance croissante avec une saisonnalité marquée, tandis que la seconde illustre une évolution plus stable, caractérisée par des fluctuations saisonnières modérées. Ces résultats soulignent la capacité du modèle Holt-Winters à reproduire fidèlement la structure temporelle des deux séries.

5.2.5.2 Le modèle XGBoost

Le modèle *eXtreme Gradient Boosting* (XGBoost) est un algorithme de machine learning reconnu pour sa performance, largement utilisé dans les tâches de régression et de classification. Il repose sur le principe de l'assemblage d'arbres de décision successifs, où chaque nouvel arbre apprend à corriger les erreurs des précédents. Bien qu'il ne soit pas nativement conçu pour les séries temporelles, XGBoost peut être utilisé pour la prévision

```

df_feat = df_clients.copy().reset_index()
df_feat['month'] = df_feat['Date'].dt.month
df_feat['year'] = df_feat['Date'].dt.year
df_feat['quarter'] = df_feat['Date'].dt.quarter
df_feat['dayofyear'] = df_feat['Date'].dt.dayofyear

X = df_feat[['month', 'year', 'quarter', 'dayofyear']]
y = df_feat['y']
X_train = X.iloc[:train_size]
y_train = y.iloc[:train_size]

model_xgb = XGBRegressor()
model_xgb.fit(X_train, y_train)

future_dates = pd.date_range(df_feat['Date'].max() + pd.DateOffset(months=1), periods=36, freq='M')
future_X = pd.DataFrame({
    'month': future_dates.month,
    'year': future_dates.year,
    'quarter': future_dates.quarter,
    'dayofyear': future_dates.dayofyear
})
future_xgb = model_xgb.predict(future_X)
future_xgb = pd.Series(future_xgb, index=future_dates)

```

FIGURE 5.8 : Script de l'impl mentation du mod le XGBoost

en transformant le probl me en une t che supervis e [26]. Pour cela, nous avons d riv  plusieurs attributs temporels   partir des dates disponibles : Mois, ann e et jour de l'ann e. Ces variables permettent au mod le de capturer les tendances et les effets saisonniers pr sents dans les donn es (voir figure 5.8). L'impl mentation a  t  r alis e   l'aide de la classe `xgb.XGBRegressor()` de la biblioth que `xgboost` en utilisant les param tres par d faut. Le mod le a  t  entra n    l'aide de la m thode `fit()` sur les donn es d'entra nement `X_train` et `y_train`, puis appliqu    des dates futures pour r aliser les pr visions   l'aide de la fonction `predict()`. Les figures 5.9 et 5.10 pr sentent respectivement les pr visions du chiffre d'affaires et du nombre de clients   l'aide du mod le XGBoost. Les figures montrent que le mod le XGBoost capture globalement les variations saisonni res du chiffre d'affaires, tandis que la pr vision du nombre de clients pr sente une dynamique plus irr guli re. Ces r sultats sugg rent que le mod le reste efficace pour identifier des tendances courtes, mais moins adapt  aux structures temporelles fortement d pendantes.




FIGURE 5.9 : Illustration des r sultats de pr vision du chiffre d'affaires   l'aide du mod le XGBoost




FIGURE 5.10 : Illustration des r sultats de pr vision du nombre de clients   l'aide du mod le XGBoost

5.2.5.3 Le mod le ARIMA saisonnier (SARIMA)

Le mod le SARIMA (*Seasonal AutoRegressive Integrated Moving Average*) est une extension du mod le ARIMA permettant de capturer les effets saisonniers dans les s ries temporelles. Il est particuli rement adapt  aux indicateurs que nous avons  tudi s, notamment le chiffre d'affaires total et le nombre total de clients, qui pr sentent une certaine cyclicit  mensuelle [27]. Le mod le SARIMA repose sur deux groupes de param tres :

- (p, d, q) : Param tres non saisonniers pour l'autor gression, la diff renciation et la moyenne mobile.
- (P, D, Q, m) : Param tres saisonniers, avec $m = 12$ pour une p riodicite  mensuelle.

Dans notre cas, nous avons utilis  l'ordre $(1, 1, 1)$ pour la partie non saisonni re, et $(1, 1, 1, 12)$ pour la composante saisonni re, afin de bien capturer les cycles mensuels pr sents dans nos donn es. Le mod le a  t  impl ment    l'aide de la classe **SARIMAX** fournie par la biblioth que **statsmodels** apr s avoir v rifi  la stationnarit  de la s rie. Une pr vision a ensuite  t  r alis e sur une p riode de 36 mois   partir de l'ensemble d'entra nement (voir figure 5.11). Les figures 5.12 et 5.13 pr sentent respectivement les pr visions du chiffre d'affaires et du nombre de clients g n r es par le mod le SARIMA. La premi re montre une continuit  coh rente avec l'historique, en reproduisant correctement les tendances et les cycles mensuels. La seconde illustre une dynamique client plus instable, mais dont la saisonnalit  reste bien captur e. Ces r sultats confirment la capacit  du mod le SARIMA   mod liser efficacement les structures temporelles r guli res et les composantes saisonni res marqu es.

```
model_sarima = SARIMAX(train['y'], order=(1,1,1), seasonal_order=(1,1,1,12)).fit()
future_sarima = model_sarima.forecast(steps=36)
future_sarima.index = pd.date_range(df_clients.index.max() + pd.DateOffset(months=1), periods=36, freq='M')
```

FIGURE 5.11 : Script de l'impl mentation du mod le SARIMA




FIGURE 5.12 : Illustration des r sultats de pr vision du chiffre d'affaires   l'aide du mod le SARIMA




FIGURE 5.13 : Illustration des r sultats de pr vision du nombre de clients   l'aide du mod le SARIMA

5.2.6  valuation de la performance des mod les

Pour s lectionner le mod le de pr vision le plus performant, nous avons utilis  des m triques d' valuation standards en s ries temporelles.

5.2.6.1 Les m triques d' valuation

Afin d' valuer les performances des mod les sur la pr vision du chiffre d'affaires et du nombre total de clients, deux indicateurs issus de la r gression ont  t  utilis s :

- **RMSE (Root Mean Squared Error)** : Il s'agit de la racine carr e de la moyenne des carr s des erreurs. Cette m trique mesure la dispersion entre les valeurs pr dites $\hat{y}_i$ et les valeurs r elles y_i . Elle est d finie par la formule [28] :

$$\text{RMSE}(y, \hat{y}) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5.1)$$

O  :

- n : Nombre total de points de donn es (ou d'observations) ;

TABLEAU 5.12 : R sultats obtenues par les trois mod les en comparaison (SARIMA, Holt-Winters et XGBoost) pour la pr vision du chiffre d'affaires en terme de RMSE et MAE

Mod�le	RMSE	MAE
SARIMA	101.56	82.53
Holt-Winters	102.89	84.16
XGBoost	314.07	274.74

- y_i : Valeur r elle observ e   l'instant i ;
- $\hat{y}_i$: Valeur pr dite par le mod le   l'instant i ;
- $(y_i - \hat{y}_i)^2$: Carr  de l'erreur de pr diction pour l'instant i .
- **MAE (Mean Absolute Error)** : Il s'agit de la moyenne des valeurs absolues des erreurs. Cette m trique  value la pr cision globale des pr dictions sans accorder plus de poids aux grandes erreurs. Elle est d finie par [29] :

$$\text{MAE}(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5.2)$$

O  :

- n : Nombre total de points de donn es ;
- y_i : Valeur r elle observ e   l'instant i ;
- $\hat{y}_i$: Valeur pr dite par le mod le   l'instant i ;
- $|y_i - \hat{y}_i|$: Valeur absolue de l'erreur de pr diction   l'instant i .

Ces m triques sont utilis es pour comparer les performances des mod les de pr vision afin d'identifier le plus fiable, c'est- -dire celui pr sentant les valeurs de *RMSE* et de *MAE* les plus faibles. L'impl mentation de ces m triques, comme illustr  dans la figure 5.14, permet d'automatiser cette comparaison pour les trois mod les  valu s.

```
df_eval_real = pd.DataFrame({
    'Mod le': ['SARIMA', 'Holt-Winters', 'XGBoost'],
    'RMSE ': [
        sqrt(mean_squared_error(y_real, future_sarima_real[:len(y_real)])),
        sqrt(mean_squared_error(y_real, future_hw_real[:len(y_real)])) if len(train) >= 24 else np.nan,
        sqrt(mean_squared_error(y_real, future_xgb_real[:len(y_real)]))
    ],
    'MAE ': [
        mean_absolute_error(y_real, future_sarima_real[:len(y_real)]),
        mean_absolute_error(y_real, future_hw_real[:len(y_real)]) if len(train) >= 24 else np.nan,
        mean_absolute_error(y_real, future_xgb_real[:len(y_real)])
    ]
})

print("\n Comparaison des mod les :")
print(df_eval_real.round(2))
```

FIGURE 5.14 : Script de comparaison des mod les de pr vision

TABLEAU 5.13 : Résultats obtenues par les trois modèles en comparaison (SARIMA, Holt-Winters et XGBoost) pour la prédiction du nombre de clients en terme de RMSE et MAE

Modèle	RMSE	MAE
SARIMA	206.91	184.84
Holt-Winters	279.66	262.77
XGBoost	360.36	320.72

5.2.6.2 Résultats obtenus

Les résultats comparatifs entre les modèles SARIMA, Holt-Winters et XGBoost pour la prédiction du chiffre d'affaires et du nombre de clients sont présentés dans les tableaux 5.12 et 5.13 respectivement. Selon ces résultats, pour le chiffre d'affaires, SARIMA offre les meilleures performances (RMSE = 101.56, MAE = 82.53), suivi de Holt-Winters avec des résultats proches. À l'inverse, XGBoost affiche des erreurs nettement plus élevées, ce qui indique une faible précision. La même tendance s'observe pour la prédiction du nombre de clients. SARIMA reste le plus précis (RMSE = 206.91, MAE = 184.84), devant Holt-Winters, tandis que XGBoost obtient les scores les plus faibles en termes de performance. Ainsi, selon les métriques utilisées, SARIMA est le modèle le plus performant pour les deux indicateurs, suivi de Holt-Winters, puis de XGBoost.

5.2.7 Déploiement

Après avoir terminé la phase de modélisation et identifié le modèle le plus performant en l'occurrence le modèle SARIMA pour les deux indicateurs clés (le chiffre d'affaires total et le nombre total de clients), nous avons procédé à la phase de déploiement afin de rendre les résultats accessibles de manière interactive. Pour cela, nous avons intégré les prévisions générées par Python directement dans Power BI. L'objectif était de permettre aux utilisateurs métier de consulter, filtrer et analyser dynamiquement les résultats selon différents critères (type de contrat, catégorie de client, agence, etc.). La figure 5.15 illustre l'interface du tableau de bord prévisionnel développé. On y retrouve :

- Une visualisation des prévisions du chiffre d'affaires total et du nombre total de clients à l'aide de courbes comparant les valeurs réelles et prédites (issues du modèle SARIMA) ;
- Des filtres interactifs permettant de personnaliser l'affichage selon la période, la catégorie de client, l'agence ou encore le type de contrat ;
- Une expérience utilisateur fluide et intuitive, permettant aux équipes commerciales ou décisionnelles de mieux anticiper les tendances futures.

Grâce à cette approche, les prévisions sont non seulement automatisées mais aussi facilement interprétables et exploitables via une interface conviviale intégrée à Power BI.




FIGURE 5.15 : Dashboard "Tableau de bord prévisionnel"

5.3 Segmentation des clients

La segmentation des clients a été réalisée en plusieurs étapes, en se basant sur des variables clés issues de leur comportement contractuel : L'ancienneté, les interruptions (`time_laps`). L'objectif est de regrouper les clients selon leur fidélité au fil du temps.

5.3.1 Préparation des données

Le fichier source contenant l'historique des contrats a été filtré afin de ne conserver que les colonnes utiles : L'année, le numéro de contrat, le code client, l'agence et la région. Après suppression des doublons, trois indicateurs comportementaux ont été calculés :

- Ancienneté : Nombre d'années successives de souscription d'un contrat ;
- `Time_laps` : Durée (en années) pendant laquelle le client a interrompu ses contrats avant de revenir.

Ces indicateurs ont été fusionnés pour constituer un jeu de données final utilisé pour la phase de segmentation.

5.3.2 Détermination du nombre optimal de clusters et application de l'algorithme K-Means

Afin de segmenter efficacement la clientèle, il est essentiel d'estimer un nombre optimal de groupes homogènes. Pour cela, nous avons utilisé la méthode ELBOW.

5.3.2.1 Choix du nombre de clusters

La méthode du *Elbow* est une technique couramment utilisée en apprentissage non supervisé pour déterminer le nombre optimal de clusters dans une classification. Elle consiste à tracer l'inertie intra-cluster (somme des distances entre chaque point et son centroïde) en fonction du nombre de clusters k , afin d'identifier un point de rupture visuel, appelé

"coude" [30]. Le nombre optimal de segments a été identifié à l'aide de la méthode du *Elbow* réalisée dans Python (voir figure 5.16), qui consiste à représenter l'inertie intra-cluster en fonction du nombre de clusters. La figure 5.17 présente la courbe obtenue par la méthode du coude, qui trace l'évolution du score de distorsion (ou inertie intra-cluster) en fonction du nombre de clusters k . Cette courbe décroît rapidement au début, indiquant une amélioration significative de la qualité de regroupement, puis la diminution devient plus lente. Le point d'inflexion observé à $k = 4$ marque le seuil au-delà duquel l'ajout de nouveaux clusters n'apporte qu'un gain marginal. Ce comportement justifie la sélection de cette valeur comme seuil optimal pour segmenter efficacement les clients tout en évitant une complexité excessive du modèle.

```
features = ['anciennete', 'time_laps']
X = df_final[features]
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

plt.figure()
model = KMeans(random_state=42, n_init=10)
visualizer = KElbowVisualizer(model, k=(2, 10))
visualizer.fit(X_scaled)
visualizer.show()
plt.show()
```

FIGURE 5.16 : Script de l'implémentation de la méthode Elbow




FIGURE 5.17 : Illustration du résultat de l'application de la méthode Elbow

5.3.2.2 Application de l'algorithme K-Means pour la segmentation

L'algorithme *KMeans* est une méthode de regroupement non supervisé qui vise à partitionner les données en k groupes homogènes, appelés clusters. Il regroupe les individus en minimisant la distance entre chaque point et le centroïde de son cluster [31]. L'algorithme

KMeans a été appliqué avec $k = 4$, et chaque client a été assigné à un cluster. Une étiquette a ensuite été attribuée à chaque groupe selon son profil dominant (voir figure 5.18) :

- Cluster 0 : Client très fidèle, avec une ancienneté de 5 ou 4 ans et `time_laps` = 0, indiquant une souscription continue sans interruption ;
- Cluster 1 : Client fidèle, avec une ancienneté de 3 ou 2 ans et `time_laps` = 0, représentant des clients réguliers avec une fidélité stable ;
- Cluster 2 : Client volatil, caractérisé par un `time_laps` strictement supérieur à 0, indiquant des interruptions de contrat suivies d'un retour ;
- Cluster 3 : Nouveau client, avec une ancienneté de 1 an et `time_laps` = 0, ce sont des clients récents sans historique d'interruption.

La figure 5.19 illustre la répartition des clients sur un plan en deux dimensions (`ancienneté` vs. `time_laps`), colorée selon leur segment. On observe que :

- les clients très fidèles (cluster 0) apparaissent en bas à droite, avec une ancienneté élevée (4 ou 5 ans) et aucun `time_laps` ;
- les clients fidèles (cluster 1) sont situés au centre bas du graphique, avec une ancienneté moyenne (2 à 3 ans) et `time_laps` = 0 ;
- les nouveaux clients (cluster 3) sont isolés en bas à gauche (`ancienneté` = 1 an, `time_laps` = 0) ;
- les clients volatils (cluster 2) se trouvent dans la partie supérieure, marquée par un `time_laps` strictement positif, quelle que soit leur ancienneté.

```
k = 4
kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
df_final['cluster'] = kmeans.fit_predict(X_scaled)

def label_cluster(row):
    if row['cluster'] == 0:
        return "Très fidèle"
    elif row['cluster'] == 1:
        return "Fidèle"
    elif row['cluster'] == 2:
        return "Volatil"
    else:
        return "Nouveau"
df_final['Type_Client'] = df_final.apply(label_cluster, axis=1)
print(df_final['cluster'].value_counts())

plt.figure()
plt.scatter(df_final['anciennete'], df_final['time_laps'],
            c=df_final['cluster'], cmap='viridis', s=60)
plt.xlabel('Ancienneté')
plt.ylabel('Time_Laps')
plt.title('Segmentation des clients avec KMeans')
plt.colorbar(label='Cluster')
plt.grid(True)
plt.show()
```

FIGURE 5.18 : Script de l'implémentation de l'algorithme K-Means

5.3.3 Export des données segmentées

Le fichier final enrichi de la variable `Type_Client` a été exporté au format CSV afin d'être intégré dans Power BI pour l'analyse dynamique des segments et leur impact commercial.




FIGURE 5.19 : Visualisation de la segmentation des clients par K-Means

5.3.4 Intégration dans Power BI

La segmentation a été intégrée dans Power BI afin de permettre une visualisation dynamique et interactive des différents profils clients. Le tableau de bord présenté dans la figure 5.20 propose une analyse complète à l'aide de filtres et de visuels variés, facilitant l'exploration des données. Les éléments visuels sont détaillés dans le tableau 5.14, chacun offrant une perspective spécifique sur la répartition, la performance commerciale et la localisation des segments clients. Cette interface intuitive permet désormais d'orienter plus efficacement les actions marketing, d'identifier les profils à risque de désengagement et d'ajuster les offres commerciales en fonction des comportements historiques observés.




FIGURE 5.20 : Tableau de bord "Segmentation des clients"

TABLEAU 5.14 : Description des visuels du tableau de bord "Segmentation des clients"

Type de visuel	Description du visuel	Interprétation
Diagramme en arbre (Répartition du nombre de clients par segment)	Affichage arborescent montrant le volume total de clients segmentés selon leur profil. Chaque branche représente un groupe distinct.	La majorité des clients sont classés comme "très fidèles" (plus de 12 000), suivis des clients réguliers et fidèles. Cela reflète une base de clients stable et engagée.
Diagramme circulaire (Répartition du chiffre d'affaires)	Camembert représentant la contribution de chaque type de client au chiffre d'affaires global.	Les clients très fidèles génèrent plus de 38 % du chiffre d'affaires, suivis des nouveaux clients (37 %), ce qui montre l'importance des deux extrêmes.
Barres horizontales (Performance commerciale par profil client)	Barres horizontales illustrant la valeur commerciale de chaque segment client. Permet d'identifier les profils les plus rentables.	Les clients très fidèles représentent à eux seuls plus de 139M TND. Les autres segments ont un impact beaucoup plus modéré.
Tableau (Matrice des informations de segmentation)	Tableau interactif listant le code client, le contrat, le segment attribué et le chiffre d'affaires associé.	Les clients très fidèles apparaissent le plus souvent, avec des chiffres d'affaires élevés. Le tableau permet d'analyser rapidement la typologie client.
Carte géographique (Répartition régionale des segments clients)	Carte de la Tunisie avec des points localisés indiquant la concentration des profils clients par région.	Les régions côtières comme Tunis, Sfax et Sousse regroupent la majorité des clients très fidèles. Cela peut orienter les campagnes ciblées.

5.4 Prédiction du comportement des clients

L'objectif de cette section est de prédire le comportement des clients (fidèles ou résiliés) à l'aide de modèles d'apprentissage automatique. Deux modèles ont été développés et comparés à l'aide de plusieurs métriques d'évaluation afin de sélectionner le plus performant.

5.4.1 Préparation des données

Avant d'entraîner les modèles de machine learning, une phase rigoureuse de préparation des données a été réalisée. Celle-ci comprend à la fois la compréhension des variables, le nettoyage des enregistrements et l'équilibrage de la variable cible.

Les données proviennent d'un fichier CSV (voir figure 5.21) regroupant plusieurs années de contrats d'assurance. Chaque ligne correspond à un contrat souscrit par un client donné,

avec des informations comme l'année, la région, le type de contrat, le chiffre d'affaires (CA), les pertes, les gains, ainsi que des identifiants clients et agences.

- Après chargement, seules les colonnes utiles ont été conservées et les valeurs manquantes supprimées.
- Les données ont été nettoyées : Typage des colonnes, conversion des montants numériques, et suppression des doublons par client et par année.
- Des variables dérivées ont été construites, notamment :
 - **ancienneté** : Nombre maximal d'années consécutives de souscription ;
 - **time_laps** : Interruption constatée dans les années de souscription ;
- Une variable cible **client_quitte** a été introduite : Elle prend la valeur 1 si le client a eu une interruption (**time_laps** > 0) en 2024, sinon 0.
- Les variables qualitatives (Statut, Type de contrat, Type de client) ont été encodées numériquement via **LabelEncoder**.
- Le jeu de données final contient une seule ligne par client, intégrant les indicateurs agrégés.

RÉGION	CA	Perte	CA_Gain	Statut	CATEGORIE_CLIENT	TMP_TYPE_CDE	anciennete	time_laps	nombre_du_contrat
Tunis	-364.65	364.65	0.0	Individuel	Personne physique	A	1	0	1
Ariana	686.575	0.0	686.575	Individuel	Personne physique	T	2	0	2
Tunis	2314.844	0.0	2314.844	Individuel	Personne physique	T	5	0	3
Tunis	359.35	0.0	359.35	Individuel	Personne physique	T	5	0	3
Sfax	398.68	0.0	398.68	Individuel	Personne physique	T	5	0	3
Tunis	1756.534	0.0	1756.534	Individuel	Personne physique	C	5	0	3
Tunis	541.433	0.0	541.433	Individuel	Personne physique	T	2	0	2
Tunis	345.05	0.0	345.05	Individuel	Personne physique	T	5	0	3
Tunis	-488.45	488.45	0.0	Individuel	Personne physique	A	1	0	1
Tunis	472.039	0.0	472.039	Individuel	Personne physique	T	5	0	3
Sfax	1623.435	0.0	1623.435	Individuel	Personne physique	T	5	0	5
Sfax	301.8	0.0	301.8	Individuel	Personne physique	T	5	0	8
Nabeul	40.0	0.0	40.0	Individuel	Personne physique	C	1	0	1
Tunis	463.65	0.0	463.65	Individuel	Personne physique	T	3	0	2
Nabeul	1625.695	0.0	1625.695	Individuel	Personne physique	T	5	0	5
Sfax	157.0	0.0	157.0	Individuel	Personne physique	C	1	0	1
Tunis	401.23	0.0	401.23	Individuel	Personne physique	T	5	0	3
Tunis	579.22	0.0	579.22	Individuel	Personne physique	T	5	0	5
Tunis	391.2	0.0	391.2	Individuel	Personne physique	T	5	0	3
Tunis	692.79	0.0	692.79	Individuel	Personne physique	T	5	0	3
Tunis	410.64	0.0	410.64	Individuel	Personne physique	T	5	0	3
Sousse	5240.702	0.0	5240.702	Individuel	Personne physique	T	5	0	3
Ariana	3218.936	0.0	3218.936	Individuel	Personne physique	T	4	0	2
Sfax	1358.2	0.0	1358.2	Individuel	Personne physique	T	5	0	3

FIGURE 5.21 : Aperçu des données sources après nettoyage

5.4.2 Construction des modèles

Pour réaliser la prédiction de comportement des clients, deux modèles ont été développés : Un modèle Random Forest et un modèle de Régression Logistique.

5.4.2.1 Random Forest

Le modèle Random Forest est un ensemble d'arbres de décision. Il construit plusieurs arbres à partir de sous-échantillons de données et combine leurs résultats pour renforcer la précision et limiter le surapprentissage [32]. La figure 5.22 présente le script Python utilisé pour ce modèle.

- Utilisation de **RandomForestClassifier** pour la classification ;
- Validation croisée mise en œuvre à l'aide de **StratifiedKFold**, qui consiste à diviser les données en 5 sous-groupes.

```
model_rf = RandomForestClassifier(  
    class_weight='balanced',  
    max_depth=3,  
    min_samples_leaf=10,  
    n_estimators=100,  
    random_state=42  
)  
model_rf.fit(X_train, y_train)  
  
pred_rf = model_rf.predict(X_test)
```

FIGURE 5.22 : Script de l'implémentation du modèle Random Forest

5.4.2.2 Régression Logistique

La Régression Logistique est un modèle linéaire utilisé pour résoudre des problèmes de classification binaire. Elle estime la probabilité d'appartenance à une classe à partir d'une combinaison linéaire des variables d'entrée [33]. Le code utilisé pour sa mise en œuvre est montré dans la figure 5.23.

- Implémentation avec `LogisticRegression(max_iter=1000)` ;
- Validation croisée effectuée sur cinq plis.

```
model_rl = LogisticRegression(class_weight='balanced', max_iter=1000, random_state=42)  
model_rl.fit(X_train, y_train)  
pred_rl = model_rl.predict(X_test)
```

FIGURE 5.23 : Script de l'implémentation du modèle Régression Logistique

5.4.3 Métriques d'évaluation

Le choix des métriques d'évaluation joue un rôle fondamental dans l'analyse des performances d'un modèle d'apprentissage automatique. Selon la nature des données et l'objectif de la prédiction, certaines métriques peuvent s'avérer plus pertinentes que d'autres [34]. Dans le cadre de ce projet, plusieurs indicateurs complémentaires ont été sélectionnés afin d'obtenir une évaluation globale, fiable et représentative du comportement des modèles. Certaines métriques, comme l'exactitude (accuracy), peuvent être trompeuses dans un contexte de classes déséquilibrées ou en présence de valeurs aberrantes (outliers). À l'inverse, d'autres indicateurs comme la précision, le rappel et le F1-score offrent une meilleure sensibilité à la détection des cas minoritaires, bien que la précision et le rappel puissent également être affectés par des valeurs extrêmes [35]. Ces différentes métriques, choisies pour leur complémentarité, sont résumées dans le tableau 5.15.

TABLEAU 5.15 : Métriques d'évaluation des modèles [36]

Métrique	Formule et définition	Signification des termes
Exactitude (Accuracy)	$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$ Proportion de bonnes prédictions parmi l'ensemble des cas.	TP = Vrai positif TN = Vrai négatif FP = Faux positif FN = Faux négatif
Précision (Precision)	$\text{Precision} = \frac{TP}{TP + FP}$ Part des clients prédits comme quittant qui le sont réellement.	FP = Client prédit "quitté" mais reste en réalité.
Rappel (Recall)	$\text{Recall} = \frac{TP}{TP + FN}$ Part des vrais clients quittant détectés par le modèle.	FN = Client a quitté, mais non détecté.
F1-score	$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$ Mesure équilibrée entre précision et rappel.	Valeur moyenne harmonique des deux.
ROC AUC	Aire sous la courbe ROC : mesure globale de la capacité à bien distinguer les classes.	Valeur entre 0 et 1.

5.4.4 Résultats obtenus

La comparaison des performances des deux modèles est présentée dans le tableau 5.16. Le modèle Random Forest surpasse la régression logistique sur toutes les métriques, notamment en termes de précision et de F1-score. Les matrices de confusion présentées dans les figures 5.24 et 5.25 illustrent bien cette différence : Random Forest distingue correctement presque tous les cas, avec très peu d'erreurs. En revanche, la Régression Logistique génère un grand nombre de faux positifs, ce qui explique sa faible précision malgré un bon rappel. Compte tenu de ses résultats, le modèle Random Forest a été sélectionné pour la mise en production. Pour renforcer la fiabilité des prédictions, une règle métier a été ajoutée afin d'identifier certains clients comme quittant sans dépendre uniquement du modèle, notamment les nouveaux clients non rentables.

TABLEAU 5.16 : Comparaison des performances des deux modèles

Métrique	Random Forest	Régression Logistique
Exactitude	1.00	0.78
Précision	0.76	0.05
Rappel	1.00	0.92
F1-score	0.86	0.09
ROC AUC	1.00	0.85




FIGURE 5.24 : Matrice de confusion du modèle Random Forest




FIGURE 5.25 : Matrice de confusion du modèle Régression Logistique

5.4.5 Déploiement

Le déploiement a été réalisé en deux étapes. La première consiste à afficher une interface d'accueil contenant l'ensemble des tableaux de bord et la seconde à proposer une interface web dédiée à la prédiction du comportement des clients.

5.4.5.1 Interface d'accueil

L'interface d'accueil permet d'accéder à l'ensemble des fonctionnalités de l'application, y compris la prédiction du comportement des clients, à travers des boutons clairs et organisés. Comme illustré dans la figure 5.26, cette page regroupe les principaux tableaux de bord : analyse des clients, des contrats, des agences, la prévision, segmentation, ainsi qu'un accès direct à la prédiction du comportement des clients. En cliquant sur le bouton dédié à la prédiction du comportement des clients, l'utilisateur est redirigé vers une interface interactive.




FIGURE 5.26 : Page d'accueil

5.4.5.2 Interface de prédiction du comportement des clients

L'interface de prédiction du comportement des clients est une application web interactive développée avec Gradio. Elle permet à l'utilisateur de saisir un code client afin d'afficher automatiquement les informations clés, telles que l'ancienneté, le nombre de contrats, le type de client (nouveau ou fidèle), ainsi que les gains et pertes enregistrés. L'interface génère ensuite une prédiction sur son comportement futur (quitter ou rester), de manière claire et accessible. Comme illustré dans la figure 5.27, l'utilisateur saisit simplement le code client, puis clique sur le bouton *Soumettre* pour obtenir les résultats. La figure 5.28 présente un exemple de prédiction pour le client 196360. Ce dernier est un nouveau client, avec un seul contrat, une ancienneté d'un an, aucun gain et une perte totale de 18,396 DT. Il est prédit comme "quittant" avec un score de confiance de 100 %. En complément, un graphique illustre la position du client par rapport aux autres, en fonction de l'ancienneté et du gain total. Le point rouge, situé en bas du graphique, met en évidence une absence totale de gain, soulignant une contribution financière nulle accompagnée d'une perte.

Prédiction du comportement des clients

Entrer le code client

Résultat

Effacer

Soumettre

Position du client



Flag

FIGURE 5.27 : Interface interactive de prédiction du comportement des clients



FIGURE 5.28 : Exemple de prédiction du comportement des clients

5.5 Conclusion

Ce chapitre a présenté une démarche analytique appliquée aux données de l'assurance automobile. La prévision des indicateurs, la segmentation des clients et la prédiction de leur comportement ont permis de développer des outils d'aide à la décision. Ces résultats offrent à l'assurance BIAT une meilleure compréhension de son portefeuille, une capacité à anticiper les risques et des bases solides pour orienter ses actions commerciales de manière ciblée et efficace.

Conclusion générale

Ce projet de fin d'études a été réalisé au sein de l'entreprise assurance BIAT , dans un contexte marqué par une gestion traditionnelle des données : Collecte manuelle, absence de centralisation, rapports en Excel et aucun outil d'anticipation ou d'analyse approfondie. Cette organisation limitait considérablement la réactivité de l'entreprise et sa capacité d'analyse, notamment pour le produit d'assurance automobile.

Face à ces défis, l'entreprise a exprimé plusieurs besoins : Disposer de tableaux de bord dynamiques pour suivre les KPIs en temps réel, anticiper leur évolution grâce à des modèles de prévision, segmenter les clients de manière automatisée et prédire leur comportement (résiliation, fidélité).

Dans ce cadre, nous avons conçu une solution complète et structurée. D'abord, nous avons analysé le contexte du produit automobile et les besoins décisionnels afin de proposer une approche adaptée. Ensuite, un processus ETL a été développé avec Python pour nettoyer, transformer et unifier les données issues de différentes sources. Puis, nous avons construit des tableaux de bord interactifs via Microsoft Power BI, permettant de visualiser les KPIs liés aux clients, contrats et agences, ainsi faciliter la prise de décision. Nous avons intégré des modèles prédictifs (SARIMA) pour estimer l'évolution du chiffre d'affaires et du nombre de clients, tout en assurant une visualisation claire des tendances. L'algorithme K-Means a été utilisé pour segmenter les clients. Enfin, nous avons appliqué un modèle Random Forest afin de prédire le comportement des clients, notamment leur propension à résilier leur contrat.

Notre solution couvre ainsi toutes les étapes de la préparation des données à leur valorisation par des KPIs, des prévisions et une analyse comportementale, dans un environnement ergonomique pensé pour les utilisateurs métier. Des pistes d'amélioration sont envisageables pour enrichir cette solution :

- Étendre la solution décisionnelle à d'autres produits d'assurance par exemple l'assurance vie ;
- Intégrer des flux de données en temps réel (via des API ou systèmes de collecte automatisée) pour renforcer la réactivité décisionnelle[37] ;
- Mettre en place un système de recommandation personnalisé basé sur les profils clients [38].

Ce stage a été une expérience très enrichissante : il nous a permis d'acquérir des compétences solides en BI, modélisation prédictive et conception de solutions décisionnelles. Nous remercions vivement nos encadrants pour leur soutien et leur confiance. Ce projet constitue une étape importante dans notre parcours professionnel et personnel.

Bibliographie

- [1] Biat assurance. <https://www.assurancesbiat.com.tn>. visité 04/02/2025.
- [2] Méthode de scrum. <https://www.journaldunet.fr/web-tech/guide-de-l-entreprise-digitale/1443834-scrum-maitriser-le-framework-star-des-methodes-agiles/>. visité : 11/02/2025.
- [3] Shéma en flocon. https://en.wikipedia.org/wiki/Snowflake_schema. visité : 02/03/2025.
- [4] Les avantages de scrum. <https://asana.com/fr/resources/what-is-scrum>. visité : 11/02/2025.
- [5] Méthode de gimsi. <https://www.piloter.org/images/gimsi-1.jpg>. visité : 11/02/2025.
- [6] Les avantage de gimsi. <https://www.piloter.org/mesurer/methode/methode-GIMSI-phases.htm>. visité : 11/02/2025.
- [7] Les limites de gimsi. https://www.piloter.org/mesurer/methode/fondamentaux_gimsi.htm. visité : 11/02/2025.
- [8] Comparaison entre scrum et gimsi. https://www.piloter.org/mesurer/methode/fondamentaux_gimsi.htm. visité : 11/02/2025.
- [9] tableau de bord. <https://coggle.it/diagram/Zxfvae2sEHE5igz5/t/comparaison-entre-scrum-et-gimsi>.
- [10] Approche inmon. <https://www.geeksforgeeks.org/difference-between-kimball-and-inmon>. visité : 11/03/2025.
- [11] inmon et kimball. <https://www.astera.com/fr/type/blog/data-warehouse-concepts/>. visité : 11/03/2025.
- [12] Avantages du shéma en étoile. <https://www.astera.com/fr/type/blog/star-schema-vs-snowflake-schema/>. visité : 11/03/25.
- [13] Shéma en étoile. https://en.wikipedia.org/wiki/Star_schema. visité : 02/03/2025.
- [14] Les limites de scrum. <https://www.lucidchart.com/blog/fr/3-majeurs-inconvenients-de-la-methode-agile>. visité : 11/02/2025.
- [15] Shéma en constellation de faits. <https://www.educba.com/data-warehouse-schema/>. visité : 02/03/2025.
- [16] Définition d'un etl. <https://fr.wikipedia.org/wiki/Extract-transform-load>. visité : 11/03/2025.
- [17] Définition de python. <https://www.journaldunet.fr/web-tech/dictionnaire-du-webmastering/1445304-python-definition-et-utilisation-de-ce-langage-informatique/>.
- [18] Définition de spyder. <https://www.wildcodeschool.com/lexique/spyder>.

- [19] Définition de pandas. <https://fr.wikipedia.org/wiki/Pandas#:~:text=Pandas%20est%20une%20biblioth%C3%A8que%20%C3%A9crite,num%C3%A9riques%20et%20de%20s%C3%A9ries%20temporelles>. visité : 12/03/2025.
- [20] Définition de numpy. <https://datascientest.com/numpy>. visité : 12/03/2025.
- [21] Définition de openpyxl. <https://www.tresfacile.net/la-bibliotheque-openpyxl-python/>. visité : 12/03/2025.
- [22] Définition de power bi. https://fr.wikipedia.org/wiki/Microsoft_Power_BI. visité : 12/03/2025.
- [23] Damodar N. Gujarati et Dawn C. Porter. Basic econometrics. https://cbpbu.ac.in/userfiles/file/2020/STUDY_MAT/ECO/1.pdf. visité : 15/05/2025.
- [24] Deepesh Machiwal and Madan K Jha. Comparative evaluation of statistical tests for time series analysis : application to hydrological time series/evaluation comparative de tests statistiques pour l'analyse de séries temporelles : application à des séries temporelles hydrologiques. *Hydrological Sciences Journal*, 53(2) :353–366, 2008. visité : 15/05/2025.
- [25] Définition de holt-winters. <https://fr.statisticseasily.com/glossaire/Qu%27est-ce-que-la-m%C3%A9thode-Holt-Winters%2C-guide-complet/>. visité : 15/05/2025.
- [26] Définition de xgboost. [https://www.ibm.com/fr-fr/think/topics/xgboost#:~:text=XGBoost%20\(eXtreme%20Gradient%20Boosting\)%20est,utilise%20la%20descente%20de%20gradient](https://www.ibm.com/fr-fr/think/topics/xgboost#:~:text=XGBoost%20(eXtreme%20Gradient%20Boosting)%20est,utilise%20la%20descente%20de%20gradient). visité : 15/05/2025.
- [27] Définition de sarima. <https://www.techniques-ingenieur.fr/base-documentaire/technologies-de-l-information-th9/traitement-du-signal-bases-theoriques-42295210/series-temporelles-te5220/processus-sarima-et-a-correlation-periodique-te5220niv10007.html>. visité : 15/05/2025.
- [28] Formule de l'équation rmse. https://docs.oracle.com/cloud/help/fr/pbcs_common/PFUSU/insights_metrics_RMSE.htm#PFUSU-GUID-FD9381A1-81E1-4F6D-8EC4-82A6CE2A6E74. visité : 15/05/2025.
- [29] Formule de l'équation mse. <https://fr.statisticseasily.com/glossaire/qu%27est-ce-que-l%27erreur-quadratique-moyenne-mse/#:~:text=La%20formule%20de%20calcul%20de,au%20nombre%20r%C3%A9el%20d'observations>. visité : 15/05/2025.
- [30] Définition de la méthode elbow. <https://www.intelligence-artificielle-school.com/ecole/technologies/k-means-algorithme/#:~:text=Initialisation%20des%20centro%C3%AFdes&text=La%20m%C3%A9thode%20Elbow%20est%20une,puis%20de%20les%20repr%C3%A9senter%20graphiquement>. visité : 17/05/2025.
- [31] Shi Na, Liu Xumin, and Guan Yong. Research on k-means clustering algorithm : An improved k-means clustering algorithm. In *2010 Third International Symposium on intelligent information technology and security informatics*, pages 63–67. Ieee, 2010. visité : 17/05/2025.
- [32] Définition du modèle random-forest. <https://www.intelligence-artificielle-school.com/ecole/technologies/random-forest-en-machine-learning/#:~:text=Il%20s'agit%20d'une,plusieurs%20jeux%20d'entra%C3%AEnement%20diff%C3%A9rents>. visité : 18/05/2025.

- [33] Définition du modèle régression logistique. <https://www.intelligence-artificielle-school.com/ecole/technologies/la-regression-logistique/>. visité : 18/05/2025.
- [34] Tahani Daghistani and Riyad Alshammari. Comparison of statistical logistic regression and random forest machine learning techniques in predicting diabetes. *Journal of Advances in Information Technology Vol*, 11(2) :78–83, 2020. visité : 18/05/2025.
- [35] Marjolaine Lannes, Nicolas Coulombel, and Yelva Roustan. Modèle désagrégé de choix de voiture par les ménages : comparaison des modèles de choix discret et d'apprentissage supervisé. Technical report, 2022. visité : 19/05/2025.
- [36] Les formules des métriques d'évaluation des modèles prédictifs. <https://fr.statisticseasily.com/exactitude-rappel-de-pr%C3%A9cision-ou-f1-quelle-m%C3%A9trique-pr%C3%A9vaut/>. visité : 20/05/2025.
- [37] Intégrer des flux de données en temps réel. <https://www.astera.com/fr/type/blog/how-to-use-apis-for-data-retrieval/>. visité : 21/05/2025.
- [38] Système de recommandation. <https://interstices.info/les-systemes-de-recommandation-categorisation/>. visité : 21/05/2025.